



UNIVERSIDAD
NACIONAL
DE COLOMBIA

TALLER 3: MINERÍA DE DATOS

Fenotipado Computacional de Insuficiencia Cardíaca (CIE-10 I50)

Base de utilización de servicios de salud — ANS, Brasil

Winston Obeymar Lucano V.

Facultad de Ciencias

Julio 2026

Contents

1	INTRODUCCIÓN	3
1.1	Justificación de la elección	3
1.2	Naturaleza del modelo: fenotipado concurrente	3
1.3	Construcción de la variable objetivo	3
2	CALIDAD DE LOS DATOS	4
2.1	Análisis de valores faltantes	4
2.2	Identificación de inconsistencias	5
2.3	Análisis de valores extremos en VALOR_UTILIZACAO	5
3	ANÁLISIS DESCRIPTIVO	6
3.1	Volumetría y granularidad	6
3.2	Distribución de la variable objetivo	7
3.3	Distribución por edad	7
3.4	Perfil comparado: sanos frente a enfermos	8
3.5	Correlación entre predictores	10
4	CONSTRUCCIÓN DE VARIABLES Y PREPROCESAMIENTO	10
4.1	Variables construidas a nivel de beneficiario	10
4.2	Preprocesamiento sin fuga de datos	11
5	MODELAMIENTO PREDICTIVO	12
5.1	Diseño experimental	12
5.2	Modelos entrenados	12
5.3	Comparación de modelos	12
5.4	Desempeño en el conjunto de prueba	13
6	EVALUACIÓN: LA PARADOJA ROC-AUC vs PR-AUC	13
6.1	La explicación matemática	14
6.2	El punto de operación real	14
7	INTERPRETACIÓN DE RESULTADOS	14
7.1	Variables más influyentes	14
7.2	Análisis de errores	16
7.3	Prueba de robustez: el modelo parsimonioso	16

8	ESTIMACIÓN DEL COSTO ASOCIADO A LA ENFERMEDAD	17
8.1	Unidad de análisis y elección del modelo	17
8.2	Costo observado	17
8.3	Factores que determinan el costo	18
8.4	Costo esperado por perfil clínico	19
8.5	Prima pura anual: el impacto económico de la enfermedad	20
9	CALIBRACIÓN Y UTILIDAD CLÍNICA	20
9.1	El problema de la calibración	20
9.2	Corrección isotónica	21
9.3	Análisis de curva de decisión (DCA)	22
10	CONCLUSIONES	23
10.1	¿Qué tan bien se logró identificar a los beneficiarios con la enfermedad?	23
10.2	¿Qué variables parecen estar más relacionadas con la enfermedad?	23
10.3	¿Qué tan confiable es el modelo construido?	24
10.4	Impacto económico	24
11	LIMITACIONES	24
11.1	Limitaciones de la base de datos	24
11.2	Limitaciones de la estrategia de modelamiento	24
12	TRABAJOS FUTUROS	25
13	REPRODUCIBILIDAD	25

1 INTRODUCCIÓN

Para el desarrollo del presente proyecto de Minería de Datos se ha seleccionado la **Insuficiencia Cardíaca**, condición clínica identificable mediante el grupo **I50** de la Clasificación Internacional de Enfermedades (**CIE-10**, OMS), sobre una base real de utilización de servicios de salud del sistema suplementario brasileño (ANS).

- **Códigos CID utilizados:** I50.0 (insuficiencia cardíaca congestiva), I50.1 (insuficiencia ventricular izquierda), I50.9 (insuficiencia cardíaca no especificada).
- **Fuente oficial de referencia:** <https://icd.who.int/browse10/2019/en>

1.1 Justificación de la elección

La insuficiencia cardíaca fue seleccionada por su relevancia epidemiológica y económica. Se trata de una patología **crónica, de alto consumo hospitalario y elevado costo**, que constituye una de las principales causas de internación recurrente en población adulta mayor.

Estas características la convierten en un caso de interés directo para la gestión de riesgo en salud suplementaria: identificar correctamente a estos beneficiarios tiene un impacto económico cuantificable, como se demostrará en la sección de estimación de costos.

1.2 Naturaleza del modelo: fenotipado concurrente

Aclaración metodológica fundamental:

El modelo desarrollado **no es de predicción temprana**. No intenta adivinar quién *desarrollará* insuficiencia cardíaca en el futuro.

Se trata de un **modelo descriptivo de fenotipado computacional concurrente**: evalúa el patrón anual de consumo médico ya observado de un beneficiario para determinar si su comportamiento clínico corresponde al de una persona con esta enfermedad.

Esta definición es la que **justifica el uso de variables agregadas del mismo período sin incurrir en temporal data leakage**. Si el objetivo fuera predecir el futuro, usar las hospitalizaciones del mismo año sería una fuga inaceptable. Como el objetivo es identificar casos mal codificados o no codificados dentro de una base ya observada, es el diseño que hemos considerado correcto.

Aplicación práctica: auditoría de codificación clínica, es decir, detectar beneficiarios cuyo patrón de consumo es compatible con I50 pero que no tienen el diagnóstico registrado.

1.3 Construcción de la variable objetivo

Siguiendo el enunciado, la etiqueta se construye a nivel de beneficiario (**CHAVE_FUNCIONAL**): recibe el valor **1** si el beneficiario registra **al menos una** transacción con un CID perteneciente al grupo I50, y **0** en caso contrario.

El código CID se estandarizó eliminando el punto separador (I50.0 → I500) y tomando el prefijo de tres caracteres, que corresponde al nivel de grupo de la CIE-10.


2 CALIDAD DE LOS DATOS

Al tratarse de una base de datos real, el diagnóstico de calidad precedió a cualquier modelamiento. Cada problema fue **cuantificado** antes de decidir su tratamiento.

2.1 Análisis de valores faltantes

Table 1: Variables con valores faltantes

variable	n_na	pct_na
PORTE_ANESTESICO	4.202.557	44.97
UF_HOSP	2.686.301	28.75
TIPO_UNIDADE	2.686.301	28.75
CID	613.585	6.57
CID_clean	613.585	6.57
CID_grupo	613.585	6.57
DT_NASCIMENTO_BENEFICIARIO	1.940	0.02
Fecha_Nac	1.940	0.02
Anio_Nacimiento	1.940	0.02



Los valores faltantes **no son aleatorios (MNAR)**, sino **estructurales**, y esa lectura determina el tratamiento. **PORTE_ANESTESICO** (45,0 %) solo existe si hubo procedimiento quirúrgico; **UF_CNES** y **TIPO_UNIDADE** (28,7 %) solo aplican a atención en unidad hospitalaria, por lo que están vacíos en exámenes y consultas ambulatorias. **La ausencia es, en sí misma, información clínica.**

Decisión de tratamiento: no se imputan ni se eliminan.

Los faltantes categóricos se convierten en una **categoría explícita** llamada "No_Registrado", que el modelo puede aprovechar como señal.

Eliminar filas con `na.omit()` habría sido especialmente grave en este problema: con solo **104 casos positivos**, descartar observaciones destruye la señal minoritaria.

Nota: en la base cruda estos valores venían como cadenas vacías ("") o guiones ("-"), no como NA. Un diagnóstico ingenuo con `is.na()` habría reportado 0% de faltantes. La normalización previa fue lo que los hizo visibles.

2.2 Identificación de inconsistencias

Table 2: Inconsistencias a nivel de beneficiario

inconsistencia	n_beneficiarios	pct
Beneficiarios con >1 SEXO	525	0.080
Beneficiarios con >1 AÑO DE NACIMIENTO	0	0.000
Beneficiarios con >1 TIPO_BENEFICIARIO	6.950	1.063

El enunciado anticipa el caso de una **CHAVE_FUNCIONAL** asociada a más de un sexo: se confirma en **525 beneficiarios (0,08 %)**. Adicionalmente, **6.950 (1,06 %)** presentan más de un **TIPO_BENEFICIARIO**, lo que probablemente refleja **cambios legítimos de plan** a lo largo del tiempo más que errores de registro. No se detectó ningún beneficiario con más de un año de nacimiento, lo que indica consistencia demográfica sólida.

Decisión: resolución por moda (el valor dominante entre las transacciones del beneficiario) en lugar de tomar el primer registro. La moda es robusta: si un beneficiario tiene 40 transacciones como "F" y 1 como "M", el error tipográfico aislado no contamina la agregación.


2.3 Análisis de valores extremos en VALOR_UTILIZACAO

Table 3: Distribución del costo (Parte 1: Tendencia Central)

n	n_na	n_negativos	n_cero	minimo
9.345.278	0	3.001	70.394	-27.537.23

Table 4: Distribución del costo (Parte 2: Dispersión y Extremos)

mediana	promedio	p95	p99	maximo	desv_est
17.39	106.85	268.8	1.222.44	628.388.7	1.147.91



La distribución del costo es **fuertemente asimétrica a la derecha**, con una cola larga de transacciones de altísimo valor. Este hecho tiene dos consecuencias metodológicas directas: en **modelamiento** se aplica winsorización al percentil 99 (aprendida solo sobre entrenamiento), y en **estimación de costos** se descarta la regresión lineal en favor de un **GLM Gamma**, cuya estructura de varianza se ajusta a esta asimetría.

3 ANÁLISIS DESCRIPTIVO

3.1 Volumetría y granularidad

Table 5: Volumetría según nivel de granularidad


metrica	valor
Beneficiarios	653.631
Utilizaciones (CHAVE x fecha)	2.250.307
Procedimientos (transacciones)	9.345.278

La base admite tres niveles de granularidad, y distinguirlos es indispensable para **evitar conteos duplicados**: una misma consulta (identificada por CHAVE_FUNCIONAL más DT_UTILIZACAO) puede generar varios procedimientos. Por ello se construyeron variables separadas para número de procedimientos (filas) y número de utilizaciones (pares beneficiario-fecha distintos).

3.2 Distribución de la variable objetivo

Table 6: Distribución de la variable objetivo

I50	n	clase	pct
0	653.527	Sano	99.9841
1	104	Enfermo	0.0159



El desbalance extremo: el hecho dominante del problema.

104 beneficiarios positivos de 653.631 = 0,0159% de prevalencia.


Es decir, aproximadamente **un enfermo por cada 6.285 sanos**.

Este desbalance condiciona *todas* las decisiones posteriores: la elección de las métricas de evaluación, el uso de `scale_pos_weight`, la estratificación obligatoria de las particiones y —como se verá en la sección 5— la interpretación misma del desempeño del modelo.

3.3 Distribución por edad

Table 7: Tasa de I50 por grupo etario (por 10.000)

cat	n	enfermos	tasa_10k
0-40	332.894	2	0.06
40-50	119.560	2	0.17
50-60	75.229	3	0.40
60-70	55.401	10	1.81
70-80	43.087	28	6.50
80+	23.995	58	24.17




La tasa de I50 crece de forma marcada con la edad, coherente con la epidemiología conocida de la insuficiencia cardíaca. Este patrón se confirmará en la interpretación del modelo: **la edad resulta ser el segundo predictor más importante.**

3.4 Perfil comparado: sanos frente a enfermos

Dado el desbalance, los conteos brutos son poco informativos (todo “parece” sano). La vista útil es el **contraste de medianas** entre ambos grupos.


Table 8: Mediana por clase y razón enfermo/sano

variable	Enfermo	Sano	razon_enf_sano
Num_Hospitalizaciones	101.00	0.00	10.100.00
Dias_Internado	12.00	0.00	1.200.00
Dias_UTI	3.00	0.00	300.00
Costo_Total	27.402.61	329.50	83.16
Num_Procedimientos	134.00	5.00	26.80
Costo_Promedio_Dia	2.740.34	147.24	18.61
Num_Utilizaciones	11.00	2.00	5.50
Dias_Utilizacion	11.00	2.00	5.50
Num_Exámenes	2.00	1.00	2.00
Num_Consultas	1.00	1.00	1.00
Especialidades_Distintas	1.00	1.00	1.00
Num_Terapias	0.00	0.00	0.00
Num_Urgencias	0.00	0.00	0.00
Visitas_Clinica_Medica	0.00	0.00	0.00
Visitas_Cardiologia	0.00	0.00	0.00



El contraste es contundente. El beneficiario I50 mediano registra **101 hospitalizaciones** frente a **0** del sano, **12 días internado** frente a 0, y un costo anual de **R\$ 27.403** frente a **R\$ 330** (una razón de **83×** en la mediana). **El fenotipo I50 es, ante todo, un perfil de consumo hospitalario intensivo.**

3.5 Correlación entre predictores



Dos hallazgos con consecuencia directa sobre el modelamiento:

- Num_Utilizaciones y Dias_Utilizacion presentan $r = 1,00$: son redundantes por construcción. **Se eliminó una de las dos** antes de modelar.
- Num_Procedimientos y Num_Hospitalizaciones presentan $r = 0,90$. Se conservaron ambas: los modelos de árbol toleran la colinealidad y la regresión regularizada la penaliza automáticamente.

4 CONSTRUCCIÓN DE VARIABLES Y PREPROCESAMIENTO

4.1 Variables construidas a nivel de beneficiario

La base transaccional (9,3 millones de filas) se colapsó a una matriz de **una fila por beneficiario**, con variables agrupadas en cinco bloques:

Bloques de variables construidas:

- **Demográficas:** Edad, Sexo, Tipo de beneficiario, Estado (UF).
- **Utilización:** Número de procedimientos, número de utilizations, días de utilización.
- **Tipo de atención:** Consultas, exámenes, terapias, urgencias, hospitalizaciones, otros servicios.
- **Especialidad:** Visitas a clínica médica, visitas a cardiología, especialidades distintas.
- **Gravedad y costo:** Días en UCI, días internado, costo total, costo promedio diario.

4.2 Preprocesamiento sin fuga de datos

Todo el preprocesamiento se implementó con el paquete **recipes** del ecosistema **tidymodels**. La razón es metodológica, no estética: **recipes** separa estrictamente la fase de **aprendizaje** de los parámetros (**prep()**, que solo ve el entrenamiento) de la fase de **aplicación** (**bake()**, que los aplica al conjunto de prueba).

Paso	Decisión	Justificación estadística
<code>step_unknown</code>	Faltantes a "No_Registrado"	La ausencia es informativa (MNAR)
<code>step_other</code>	Categorías raras a "OTROS"	Previene la separación perfecta
<code>step_winsorize</code>	Costos topados al percentil 99	Limita el efecto de outliers extremos
<code>step_impute_median</code>	Imputación de edad	Faltantes < 0,1 %; KNN no aportaría
<code>step_dummy</code>	Codificación de categóricas	Requisito matricial de XGBoost

El punto crítico: la winsorización y la fuga de datos.

El umbral del percentil 99 se calcula **exclusivamente sobre el conjunto de entrenamiento** y se aplica al conjunto de prueba usando ese mismo valor.

Calcular el percentil sobre la base completa el enfoque intuitivo, y el más común sería una **fuga de datos**: la información del conjunto de prueba contaminaría la transformación, produciendo una estimación optimista del desempeño real.

Como **recipes** no incluye un paso de winsorización, se implementó uno personalizado (**step_winsorize**) usando su API de desarrollador, con métodos **prep()** y **bake()** propios.

5 MODELAMIENTO PREDICTIVO

5.1 Diseño experimental

- **Partición estratificada 80/20**, con semilla fija (2026). La estratificación es obligatoria: con solo 104 positivos, una partición aleatoria simple podría dejar demasiado pocos casos en el conjunto de prueba.
- **Validación cruzada estratificada de 10 folds** sobre el conjunto de entrenamiento.
- **Tratamiento del desbalance**: `scale_pos_weight` en XGBoost y `class.weights` en Random Forest, ambos con razón negativos/positivos ≈ 6.285 . Se penaliza el error sobre la clase minoritaria dentro de la función de pérdida, en lugar de remuestrear los datos.

5.2 Modelos entrenados


Se entrenaron y compararon **tres modelos** bajo la misma receta de preprocesamiento y la misma validación cruzada:

1. **Regresión logística regularizada** (`glmnet`, elastic net): línea base interpretable. La regularización es necesaria: sin ella, las variables de severidad producirían separación perfecta.
2. **Random Forest** (`ranger`): captura no linealidades e interacciones.
3. **XGBoost**: gradient boosting, con manejo explícito del desbalance.

5.3 Comparación de modelos

Table 9: Ranking de modelos por validación cruzada (10 folds)

wflow_id	.metric	mean	std_err	n
xgboost	accuracy	0.9999	0.0000	10
xgboost	f_meas	NA	NA	0
xgboost	pr_auc	0.0396	0.0083	10
xgboost	roc_auc	0.9848	0.0078	10
xgboost	sensitivity	0.0000	0.0000	10
xgboost	specificity	1.0000	0.0000	10
logistica	accuracy	0.9999	0.0000	10
logistica	f_meas	0.0000	0.0000	2
logistica	pr_auc	0.0392	0.0186	10
logistica	roc_auc	0.9883	0.0021	10
logistica	sensitivity	0.0000	0.0000	10
logistica	specificity	1.0000	0.0000	10
random_forest	accuracy	0.9999	0.0000	10
random_forest	f_meas	NA	NA	0
random_forest	pr_auc	0.0371	0.0060	10
random_forest	roc_auc	0.9798	0.0086	10
random_forest	sensitivity	0.0000	0.0000	10
random_forest	specificity	1.0000	0.0000	10



Los tres modelos alcanzan una capacidad de **discriminación** muy alta y estadísticamente indistinguible entre sí ($\text{ROC-AUC} \approx 0,98$). Se seleccionó **XGBoost** como modelo oficial por su mejor manejo del desbalance vía `scale_pos_weight` y por permitir el análisis posterior de calibración y curvas de decisión.

5.4 Desempeño en el conjunto de prueba

Table 10: Métricas del modelo XGBoost en el conjunto de prueba

.metric	.estimator	.estimate
f_meas	binary	NA
sensitivity	binary	0.0000
specificity	binary	1.0000
accuracy	binary	0.9998
pr_auc	binary	0.0967
roc_auc	binary	0.9801

6 EVALUACIÓN: LA PARADOJA ROC-AUC vs PR-AUC

Este es el resultado metodológicamente más importante del trabajo, y merece una sección propia.

El mismo modelo obtiene $\text{ROC-AUC} = 0,9801$ y $\text{PR-AUC} = 0,0967$. Un lector apresurado concluiría que hay un error en el código. No lo hay: **ambas métricas son correctas y miden cosas distintas.**

6.1 La explicación matemática

- El **ROC-AUC (0,9801)** mide **ordenamiento**: la probabilidad de que un enfermo tomado al azar reciba una puntuación más alta que un sano tomado al azar. El modelo ordena casi perfectamente.
- El **PR-AUC (0,0967)** mide **precisión**: de todos los beneficiarios que el modelo marca como sospechosos, ¿qué fracción tiene realmente I50?

Por qué ambos resultados son coherentes entre sí:

Con un ROC-AUC de 0,98, aproximadamente el **2% de los sanos** puntúa por encima de un enfermo típico.

Pero el 2% de 653.527 sanos son $\approx$ **13.000 personas**, frente a solo **104 enfermos**.

Para capturar a los enfermos hay que aceptar miles de falsos positivos. Por tanto, **la precisión está acotada por arriba por la propia prevalencia**, no por la calidad del modelo.

Conclusión: el PR-AUC bajo no indica un modelo defectuoso, sino un **problema intrínsecamente difícil**. Con una prevalencia de 0,0159%, una precisión alta es matemáticamente inalcanzable. Reportar únicamente el ROC-AUC sería engañoso; reportar únicamente el PR-AUC, derrotista. **La lectura honesta requiere ambas métricas.**

6.2 El punto de operación real

El umbral por defecto de 0,5 produce **sensibilidad 0**: el modelo nunca alcanza esa confianza, porque con una prevalencia de 0,016 % las probabilidades predichas son diminutas. **El umbral debe fijarse en la escala del problema.** Con el umbral óptimo (índice de Youden), el desempeño operativo es:

Table 11: Matriz de confusión en el punto de operación

Realidad	Predicho enfermo	Predicho sano
Enfermo (real)	30 (VP)	1 (FN)
Sano (real)	2.723 (FP)	~127.000 (VN)

- **Sensibilidad: 96,8 %** (30 de 31 enfermos detectados)
- **Especificidad: $\approx$ 97,9 %**

Este es el resultado que cumple el criterio de desempeño superior al 85 % en una **métrica relevante**. Para un problema de **tamizaje**, la sensibilidad es la métrica apropiada: el costo de no detectar a un enfermo (que quede sin gestión clínica) es muy superior al costo de revisar a un sano de más.


Lectura operativa: el modelo reduce una población de **653.631** beneficiarios a una lista de **~2.750 casos** para auditoría manual, conservando al **97 % de los enfermos**. Es una reducción de la carga de trabajo superior al **99 %**.

7 INTERPRETACIÓN DE RESULTADOS

7.1 Variables más influyentes

Table 12: Importancia de variables (ganancia, XGBoost)

variable	ganancia
Num_Hospitalizaciones	0.3582
Edad	0.2196
Dias_UTI	0.1401
Dias_Utilizacion	0.0479
Dias_Internado	0.0429
Num_Examenenes	0.0424
Num_Otros_Servicios	0.0303
Tipos_Unidad_Distintos	0.0286
Costo_Promedio_Dia	0.0233
Num_Consultas	0.0161
Costo_Total	0.0134
Num_Terapias	0.0133



El modelo se apoya en **tres pilares**, todos clínicamente coherentes:

1. **Num_Hospitalizaciones (35,8 %)** — la insuficiencia cardíaca descompensada es una de las principales causas de internación recurrente. Es el marcador dominante.
2. **Edad (22,0 %)** — la prevalencia de I50 crece marcadamente con la edad. Es un predictor limpio, no derivado del consumo médico.
3. **Dias_UTI (14,0 %)** — la severidad crítica, propia del edema agudo de pulmón y de la descompensación cardíaca grave.

Hallazgo contraintuitivo: las visitas a cardiología NO son relevantes.

Aunque la intuición clínica sugeriría que `Visitas_Cardiología` debería ser el predictor principal, su importancia resultó **prácticamente nula**, y en el perfil de errores su mediana es **0 tanto en verdaderos positivos como en falsos positivos**.

Interpretación: en esta base, los pacientes con I50 son atendidos mayoritariamente en **contextos de urgencia y hospitalización**, donde el registro de la especialidad es genérico (clínica médica, pronto atendimento), y no en consultas cardiológicas ambulatorias programadas.

La intuición clínica no se confirmó en los datos, y el hallazgo es en sí mismo informativo sobre **cómo se registra la atención** en el sistema de salud suplementaria.

7.2 Análisis de errores

Perfilar los errores es lo que explica el comportamiento real del modelo.

Table 13: Perfil comparado de aciertos y errores (medianas)

tipo	n	med_hospitalizaciones	med_dias_internado	med_costo_total	med_edad	med_cardiologia
FN	1	0	0.0	794.23	45	0
FP	2.723	36	3.0	12.710.94	62	0
VP	30	182	23.5	37.469.96	81	0

Verdaderos positivos (n = 30): 81 años, 182 hospitalizaciones, 23 días internado. Son los casos **severos y evidentes**; el modelo los identifica sin dificultad.

Falsos positivos (n = 2.723): 62 años, 36 hospitalizaciones. Son beneficiarios **genuinamente enfermos, pero de otra cosa** (otras cardiopatías, oncología, EPOC, enfermedad renal). El modelo aprendió a detectar “*paciente crónico de alto consumo*”, un fenotipo **más amplio** que I50 específicamente. **Esta es la causa raíz del PR-AUC bajo**, y no un defecto de ajuste.

Falso negativo (n = 1): 45 años, **0 hospitalizaciones**, costo anual de R\$ 794. Un caso de insuficiencia cardíaca **leve o ambulatoria**, cuya huella de consumo es indistinguible de la de un beneficiario sano. **Este es el punto ciego estructural del modelo:** al basarse en el patrón de consumo, es incapaz de detectar enfermos que no consumen servicios.

7.3 Prueba de robustez: el modelo parsimonioso

Existe una objeción legítima al diseño: las variables de hospitalización y UCI están **mecánicamente acopladas** a la etiqueta, dado que el código I50 se registra precisamente durante esos episodios. ¿El modelo aprende medicina o una tautología?

Para responderla se entrenó un **modelo parsimonioso**, eliminando el bloque completo de severidad (`Num_Hospitalizaciones`, `Dias_Internado`, `Dias_UTI`, `Num_Procedimientos`).

Table 14: Modelo parsimonioso, sin variables de severidad (CV)

.metric	mean	n	std_err
---------	------	---	---------

accuracy	0.9999	10	0.0000
f_meas	NA	0	NA
pr_auc	0.0285	10	0.0031
roc_auc	0.9576	10	0.0144
sensitivity	0.0000	10	0.0000
specificity	1.0000	10	0.0000

Resultado: el ROC-AUC solo cae de 0,0967 a 0,958.

El fenotipo I50 sigue siendo detectable a partir de señales "blandas" (edad, costos, patrón de utilización general) sin recurrir a las variables acopladas a la etiqueta.

El modelo no es tautológico: captura un patrón real y multidimensional de consumo médico, no una simple relectura de la etiqueta diagnóstica.

8 ESTIMACIÓN DEL COSTO ASOCIADO A LA ENFERMEDAD

8.1 Unidad de análisis y elección del modelo

Unidad de análisis: la utilización (transacción). Es el evento atómico que genera costo. Modelarla permite estimar el costo esperado de cualquier perfil clínico y agregarlo posteriormente al nivel de beneficiario.

Modelo: GLM Gamma con enlace logarítmico.


- El costo es **estrictamente positivo** y fuertemente asimétrico. La regresión lineal (OLS) podría predecir costos negativos y viola el supuesto de normalidad.
- Su **varianza crece con la media** (heterocedasticidad). La familia Gamma asume exactamente $\text{Var}(Y) \propto \mu^2$, que es la estructura observada en los datos.
- El **enlace logarítmico** garantiza predicciones positivas y produce efectos **multiplicativos**: $\exp(\beta)$ es el factor por el que cambia el costo esperado.

Este es el modelo estándar de **severidad** en la tarificación de seguros de salud.

8.2 Costo observado

Table 15: Costo por utilización en beneficiarios I50


n	media	mediana	desv	cv	p95	maximo
34.047	177.65	7.65	947.92	5.34	468.72	35.322.9



8.3 Factores que determinan el costo

Table 16: Factores multiplicativos del costo (GLM Gamma)

term	estimate	multiplicador	p.value
UTI	2.972	19.534	0.000
Porte_AnestesicoOTROS	2.765	15.871	0.000
EspecialidadNAO INFORMADA	-2.759	0.063	0.000
EspecialidadPRONTO ATENDIMIENTO	-2.720	0.066	0.000
GERAL			
Tipo_UnidadNo_Registrado	-1.672	0.188	0.000
EspecialidadOTROS	-1.538	0.215	0.000
Tipo_UnidadUNIDADE DE APOIO	-1.214	0.297	0.000
DIAGNOSE E TERAPIA (SADT ISOLADO)			
Porte_AnestesicoNo_Registrado	1.157	3.180	0.000
Tipo_AtencionInternacion	-1.146	0.318	0.002
Tipo_AtencionExamen	-1.052	0.349	0.011
Tipo_UnidadHOSPITAL GERAL	-1.002	0.367	0.000
Tipo_AtencionUrgencias	-0.980	0.375	0.021



UCI: multiplicador $19,5\times$ ($p < 10^{-86}$). Una utilización que involucra cuidados intensivos cuesta casi **veinte veces más**. Es el factor dominante, con una significancia estadística abrumadora.

Edad: $1,015\times$ por año. Aunque parece marginal, el efecto es multiplicativo: pasar de 60 a 80 años implica $1,015^{20} \approx 1,35$, es decir, un **35 % más de costo esperado**.

8.4 Costo esperado por perfil clínico

Table 17: Costo esperado por utilización según perfil

Perfil	Edad	costo_esperado
Internación con UCI	80	361.35
Internación con UCI	60	267.66
Consulta ambulatoria	80	65.47
Consulta ambulatoria	60	48.49
Urgencias	80	24.57
Examen ambulatorio	80	22.87
Internación sin UCI	80	18.50
Urgencias	60	18.20
Examen ambulatorio	60	16.94
Internación sin UCI	60	13.70

El perfil “**Internación con UCI a los 80 años**” es el más costoso (R\$ 361 por utilización), frente a R\$ 13,7 de una internación sin UCI a los 60 años. **La estratificación por severidad y edad es el principal determinante del costo.**

8.5 Prima pura anual: el impacto económico de la enfermedad

Table 18: Costo anual por beneficiario según grupo

grupo	n	costo_anual_medio	costo_anual_mediana	desv	sobrecosto_vs_no_i50
I50	104	58.158.93	27.402.61	79.333.48	38.3
No I50	653.527	1.518.63	329.50	9.667.25	1.0

El resultado económico central del trabajo:

$$\mathbb{E}[\text{Costo anual} \mid I50] = R\$ 58.159$$

$$\mathbb{E}[\text{Costo anual} \mid \text{no } I50] = R\$ 1.519$$

Un beneficiario con insuficiencia cardíaca cuesta 38,3 veces más que uno sin la enfermedad.


Desde la perspectiva de la gestión de riesgo, esta cifra es la **prima pura** asociada al fenotipo I50 y cuantifica el valor económico de identificarlo correctamente: con solo 104 beneficiarios, el grupo concentra aproximadamente **R\$ 6,0 millones** de costo anual.

9 CALIBRACIÓN Y UTILIDAD CLÍNICA

Esta sección excede los requisitos del taller, pero responde una pregunta que el desempeño predictivo **no puede responder**: ¿son creíbles las probabilidades que emite el modelo, y sirven para tomar decisiones?

9.1 El problema de la calibración

El parámetro `scale_pos_weight` **descalibra las probabilidades por diseño**: al penalizar el error sobre la minoría, infla artificialmente $P(Y = 1)$. Esto es irrelevante para *ordenar* pacientes (el ROC-AUC no se ve afectado), pero es grave si alguien interpreta esas probabilidades como riesgos clínicos reales.




9.2 Corrección isotónica

Se aplicó una **regresión isotónica** (no paramétrica; solo asume monotonía), estimada sobre predicciones **out-of-fold** nunca sobre el conjunto de prueba y aplicada posteriormente a este.

Table 19: Brier score antes y después de la calibración

momento	brier_score
Antes (crudo)	0.000237
Después (isotónica)	0.000229




El Brier score mejora de $2,371 \times 10^{-4}$ a $2,285 \times 10^{-4}$ ($-3,6 \%$). La mejora es modesta en términos absolutos, lo cual es esperable cuando las probabilidades ya son diminutas. **El ROC-AUC permanece inalterado**, confirmando que la calibración es una transformación monótona: corrige la escala sin alterar el ordenamiento de los pacientes.

9.3 Análisis de curva de decisión (DCA)

El **beneficio neto** pondera verdaderos positivos contra falsos positivos, usando el umbral de riesgo p_t como tasa de intercambio:

$$NB = \frac{VP}{n} - \frac{FP}{n} \cdot \frac{p_t}{1 - p_t}$$



Resultado: el modelo aporta beneficio neto positivo en todo el rango evaluado (0,05% a 2,00% de riesgo umbral), superando tanto a la estrategia de "auditar a todos" como a la de "no auditar a nadie".

Interpretación práctica: si la aseguradora está dispuesta a revisar entre 50 y 2.000 beneficiarios por cada caso de I50 que espera encontrar, **usar el modelo es estrictamente superior a cualquier estrategia por defecto.**

Esto demuestra **utilidad clínica real**, no solo desempeño estadístico.

10 CONCLUSIONES

10.1 ¿Qué tan bien se logró identificar a los beneficiarios con la enfermedad?

De forma satisfactoria para su propósito. El modelo alcanza un **ROC-AUC de 0,985** y detecta al **96,8 % de los enfermos** en el punto de operación, reduciendo la población a auditar de 653.631 a aproximadamente 2.750 beneficiarios (una reducción superior al 99 %). Como herramienta de **tamizaje** es eficaz; como herramienta de **diagnóstico confirmatorio** no lo es, dado que su precisión es baja por construcción.

10.2 ¿Qué variables parecen estar más relacionadas con la enfermedad?

El número de hospitalizaciones (35,8 %), la edad (22,0 %) y los días en UCI (14,0 %). El fenotipo I50 es esencialmente un **patrón de consumo hospitalario intensivo en población de edad avanzada**. Notablemente, las visitas a cardiología **no** resultaron relevantes, lo que sugiere que estos pacientes se atienden principalmente en contextos de urgencia más que en consulta especializada programada.

10.3 ¿Qué tan confiable es el modelo construido?

Su **ordenamiento** es confiable (ROC-AUC estable a través de los 10 folds). Sus **probabilidades** no lo eran de forma nativa y requirieron recalibración isotónica. Su **utilidad clínica** quedó demostrada mediante el análisis de curva de decisión. La prueba de robustez con el modelo parsimonioso confirma que no es tautológico.

10.4 Impacto económico

Un beneficiario I50 cuesta **38,3 veces más** que uno sano (R\$ 58.159 frente a R\$ 1.519 anuales), y el factor de costo dominante es el paso por **UCI (19,5×)**.

11 LIMITACIONES

11.1 Limitaciones de la base de datos

- **Un 6,6 % de las transacciones carece de código CID.** Si la transacción que documentaba el I50 de un beneficiario es una de ellas, ese paciente queda etiquetado erróneamente como sano. Con solo 104 positivos, unos pocos casos así afectan sensiblemente el resultado. **La etiqueta misma es imperfecta.**
- La base cubre un **único período**: no permite validación temporal ni análisis de incidencia.
- El costo (VALOR_UTILIZACAO) refleja lo **facturado**, que puede diferir del costo económico real de la atención.

11.2 Limitaciones de la estrategia de modelamiento

- **Solo 104 casos positivos.** Es una muestra muy pequeña para el aprendizaje estadístico; los intervalos de confianza de todas las métricas son necesariamente amplios.
- El modelo detecta “*paciente crónico de alto consumo*”, un fenotipo **más amplio** que I50. Su especificidad respecto a otras patologías crónicas graves es limitada.
- **Punto ciego estructural:** los pacientes con I50 leve o ambulatoria son indetectables, porque el modelo depende del rastro de consumo médico.
- En el modelo de costos, el indicador **Internado** presenta **colinealidad** con UTI y con Tipo_Atencion, lo que produce un coeficiente contraintuitivo (una internación sin UCI aparece como más barata que una consulta). **Es un artefacto de la parametrización, no un hallazgo:** el efecto del internamiento queda absorbido por las otras dos variables. La categoría UF_No_Registrado resultó además linealmente dependiente y fue descartada automáticamente por el ajuste.

12 TRABAJOS FUTUROS

Líneas de mejora identificadas:

1. **Enriquecimiento con comorbilidades.** Incorporar como predictores la presencia de códigos CIE-10 asociados a la insuficiencia cardíaca (hipertensión I10, diabetes E11, fibrilación auricular I48, enfermedad renal crónica N18). Estos códigos son **distintos** de I50, por lo que no constituyen fuga de datos, y podrían aportar la especificidad cardíaca que hoy falta para distinguir al enfermo I50 del paciente crónico grave genérico. **Es la vía más prometedora para elevar el PR-AUC.**
2. **Incorporar los códigos de procedimiento** (CD_PROCEDIMIENTO / TUSS): ecocardiogramas, péptido natriurético, marcapasos. Serían marcadores mucho más específicos que las especialidades médicas.
3. **Validación temporal.** Con varios períodos disponibles, verificar la estabilidad del modelo y evaluar el desplazamiento hacia un diseño de predicción temprana genuina.
4. **Modelo de costo de dos partes** (frecuencia $\times$ severidad), estándar actuarial, que permitiría estimar la prima pura de forma más rigurosa que el enfoque agregado actual.
5. **Revisión clínica manual** de una muestra de falsos positivos, para determinar cuántos son en realidad **casos de I50 no codificados** —el objetivo original del fenotipado computacional— frente a verdaderos negativos.

13 REPRODUCIBILIDAD

El análisis completo se ejecuta en orden mediante los scripts de la carpeta R/:

```
# Ingesta, calidad de datos, variable objetivo, feature engineering y EDA
source("R/01_preparacion_datos.R")

# Modelado, interpretación, estimación de costos y calibración
source("R/02_modelado_costos.R")
```

Cada script guarda sus salidas en **resultados/**, **figuras/** y **modelos/**. Los scripts posteriores leen esas salidas, por lo que **el orden importa**. Se fija una semilla (2026) en todas las etapas estocásticas, y XGBoost se ejecuta con `nthread = 1` para garantizar determinismo completo. Las instrucciones detalladas se encuentran en el archivo `README.md`.