



UNIVERSIDAD
NACIONAL
DE COLOMBIA

TALLER 4: MINERÍA DE DATOS

Sistema de Recuperación de Información sobre Literatura Científica

Artificial Intelligence Review — Springer Nature

Winston Obeymar Lucano V.

Facultad de Ciencias

Julio 2026

Contents

1	INTRODUCCIÓN Y ALCANCE	4
1.1	Arquitectura: separación entre construcción y consulta	4
2	CONSTRUCCIÓN DEL CORPUS	4
2.1	Origen y campos utilizados	4
2.2	Compleitud y criterio de inclusión	5
2.3	Idiomas presentes	5
3	PROCESAMIENTO DEL TEXTO	5
3.1	Operaciones aplicadas y omitidas	5
3.2	El pipeline de tokenización, verificado	6
3.3	Anatomía del vocabulario	7
3.4	¿Valen los bigramas lo que cuestan?	8
4	REPRESENTACIÓN VECTORIAL	9
5	TIPO DE RECUPERACIÓN	10
5.1	BM25	10
5.2	TF-IDF con similitud coseno	10
5.3	Fusión híbrida por Reciprocal Rank Fusion	10
6	REDUCCIÓN DE DIMENSIONALIDAD	11
6.1	Método y proyección de la consulta	11
6.2	Elección del número de componentes	11
6.3	Efecto sobre memoria y tiempo de respuesta	13
7	MECANISMO DE RANKING	14
8	INTEGRACIÓN EN LA APLICACIÓN	14
9	EVALUACIÓN DE RESULTADOS	15
9.1	Diseño experimental	15
9.2	Saturación del pool	16
9.3	Resultados por consulta	16
9.4	Hallazgo principal: el experimento Q4 frente a Q7	17
9.5	Acuerdo entre estrategias	17

9.6	Análisis de un resultado poco relevante	18
9.7	Interpretación de las diferencias	18
10	LIMITACIONES Y TRABAJO FUTURO	19
11	REPRODUCIBILIDAD	20

1 INTRODUCCIÓN Y ALCANCE

Este documento describe la construcción de un sistema de recuperación de información sobre el corpus de la revista **Artificial Intelligence Review** (Springer Nature), integrado como módulo nuevo dentro de la aplicación Shiny desarrollada en el Taller 2, cuyas funcionalidades previas se conservan íntegras.

El sistema recibe una consulta en lenguaje natural y devuelve artículos ordenados por relevancia. Se implementaron **cuatro estrategias** de recuperación y **una reducción dimensional** que alimenta dos de los rankings.

1.1 Arquitectura: separación entre construcción y consulta

Decisión de diseño que gobierna todo lo demás:

La aplicación **nunca** tokeniza el corpus, reconstruye la matriz vectorial ni reentrena el modelo de reducción al responder una búsqueda.

Toda representación se calcula una sola vez, fuera de línea, y se serializa en `search_index.rds`. En tiempo de consulta solo ocurre álgebra lineal sobre objetos ya construidos.

Es un requisito explícito del enunciado y también la razón de que las consultas respondan en decenas de milisegundos.

Table 1: Separación de etapas del sistema

Etapas	Cuándo ocurre	Artefacto
Extracción del corpus	Offline, ocasional	Springer_Visual_Miner.sqlite
Indexación	Offline, tras cambiar el corpus	search_index.rds
Consulta	En línea, por búsqueda	Álgebra lineal sobre el índice

2 CONSTRUCCIÓN DEL CORPUS

2.1 Origen y campos utilizados

Los artículos provienen de SpringerLink, descubiertos mediante la API pública de Crossref filtrada por el ISSN electrónico 1573-7462 y enriquecidos con una petición HTTP por artículo. Cada documento se representa con tres campos textuales, extraídos de meta-etiquetas estándar (Highwire y Dublin Core) que son considerablemente más estables que las clases CSS de la página.

Table 2: Campos que componen el texto indexable

Campo	Origen	Peso
title	meta citation_title	x3
abstract	meta dc.description	x1
keywords	meta citation_keywords / dc.subject	x2

El título y las palabras clave se repiten en el texto indexable para darles más peso que al resumen. Es la versión simple de un esquema por campos tipo BM25F. Su efecto secundario, documentado como limitación, es que infla la longitud del documento, y BM25 penaliza la longitud a través del parámetro b .

2.2 Completitud y criterio de inclusión

Table 3: Completitud del corpus

Indicador	Valor
Artículos en la base	594
Sin título	0
Sin resumen	0
Sin palabras clave	0
Excluidos por falta de texto	0
Corpus final indexado	594

Se excluye un artículo únicamente si carece **simultáneamente** de título y de resumen: sin texto no hay nada que indexar. Un artículo con título pero sin resumen entra al índice con el texto que tenga.

No se reemplazó ningún texto faltante por contenido inventado, conforme a la prohibición explícita del enunciado.

2.3 Idiomas presentes

Table 4: Distribución de idiomas en el corpus

Idioma	Artículos
English	594

El corpus es enteramente en inglés, como corresponde a una revista internacional de Springer. Esto tiene una consecuencia directa sobre el buscador: una consulta escrita en español no recupera nada por vía léxica salvo que se traduzca antes de la tokenización.

3 PROCESAMIENTO DEL TEXTO

3.1 Operaciones aplicadas y omitidas

Table 5: Operaciones de procesamiento del texto

Operación	Aplicada	Justificación
Minúsculas	Sí	El corpus no distingue mayúsculas semánticamente.
Normalización de acentos	Sí	Latin-ASCII: evita que análisis y analisis sean tipos distintos.
Puente ES-EN	Sí	Léxico de dominio: sin él una consulta en español no recupera nada.
Corrección aproximada	Solo en consultas	Distancia de edición contra léxico y vocabulario. Nunca al indexar.

Tokenización	Sí	Separación por no alfanuméricos, conservando guion interno (gpt-4).
Filtro de longitud	Sí	Mínimo 3 caracteres, con lista blanca de acrónimos (ai, ml, dl).
Eliminación de números	Sí (puros)	Un número aislado no discrimina; los alfanuméricos sí se conservan.
Stopwords	Sí	Inglés, español y una lista de dominio (paper, article, et, al).
Stemming	Sí (Porter)	No requiere diccionario externo; el sobre-truncamiento pesa menos que la dispersión.
Lematización	No	Exigiría un modelo morfológico externo con beneficio marginal.
Bigramas	Sí	Unigramas y bigramas contiguos. Su valor se somete a prueba empírica.

Por qué la corrección aproximada solo actúa en consultas:

Corregir el corpus contra su propio vocabulario sería circular: el vocabulario se deriva del corpus, así que usarlo para corregirlo equivale a validar el texto contra sí mismo.

La corrección se aplica exclusivamente al texto que escribe el usuario, comparándolo contra un vocabulario ya fijado.

3.2 El pipeline de tokenización, verificado

El siguiente bloque ejecuta el tokenizador real sobre un ejemplo del corpus, de modo que el paso de texto original a tokens indexables sea auditable y no una descripción.

```
ejemplo <- idx$meta$title[1]
substr(ejemplo, 1, 70)
```

```
## [1] "Automated machine learning in the era of large language models: a syst"
```

```
tokenizar(ejemplo, bigramas = FALSE)[[1]][1:8]      # unigramas ya stemmed
```

```
## [1] "autom"      "machin"    "learn"     "era"       "larg"      "languag"   "model"
## [8] "systemat"
```

```
tail(tokenizar(ejemplo, bigramas = TRUE)[[1]], 4)   # bigramas contiguos
```

```
## [1] "systemat_green"      "green_trustworthi"   "trustworthi_human-cent"
## [4] "human-cent_autom"
```

Y el puente español-inglés con corrección de errores, sobre una consulta que combina ambos problemas: un término mal escrito y un acrónimo de dos caracteres.

```
diagnosticar_consulta("Dianostico ml", idx)$mensaje
```

```
## [1] "2 de 2 palabras reconocidas (+0 de 1 bigramas). Se corrigio: dianostico -> diagnostico."
```

3.3 Anatomía del vocabulario

El tamaño del vocabulario final no es un parámetro elegido: es la consecuencia de dos filtros de poda. Conviene medir cuánto aporta cada uno por separado antes de justificarlos.




Figure 1: Distribución de la frecuencia documental por tipo de n-grama, en escala logarítmica.

Table 6: Aporte de cada filtro de poda, medidos por separado

Filtro	Términos
Tipos únicos iniciales	66.108
Elimina min < 3	60.366 (91.3\%)
Elimina max > 50	16 (0.02\%)
Vocabulario final	5.726

El filtro `min_df` hace prácticamente todo el trabajo, y no por capricho: un término que aparece en uno o dos documentos no puede sostener ninguna generalización. Son erratas, nombres propios o jerga irrepetible que añaden dimensiones sin poder discriminante y que, en el SVD, alimentan componentes de ruido. El **83%** de los tipos son palabras que solo aparecen una vez en todo el corpus, y de esos la inmensa mayoría son bigramas: la ley de Zipf operando sobre un espacio combinatorio.

Table 7: Términos eliminados por el filtro de frecuencia máxima

Término	df	% del corpus
artifici	594	100.0
artifici_intellig	594	100.0

comput	594	100.0
comput_scienc	594	100.0
general	594	100.0
general_artifici	594	100.0
intellig	594	100.0
intellig_comput	594	100.0
scienc	594	100.0
scienc_general	594	100.0
model	419	70.5
research	374	63.0
method	353	59.4
learn	351	59.1
challeng	342	57.6
provid	320	53.9

Un filtro que elimina el 0,02% y acierta:

Los diez primeros términos de la tabla anterior aparecen en el **100%** del corpus y forman una cadena reconocible: *Computer Science, Artificial Intelligence, General*.

No provienen de los resúmenes. Son la **taxonomía editorial de Springer**, que viaja en el campo `dc.subject` junto a las palabras clave del autor.

Que un filtro elimine apenas el 0,02% del vocabulario y que ese 0,02% sea precisamente el boilerplate editorial es la mejor justificación posible para conservarlo.

3.4 ¿Valen los bigramas lo que cuestan?

Los bigramas constituyen el 60% del vocabulario final. En lugar de asumir que ayudan, se construyó un índice paralelo únicamente con unigramas y se evaluó con los mismos juicios de relevancia.

Table 8: Ablación: unigramas solos frente a unigramas más bigramas

Representación	Términos	MB	P@5 BM25	P@5 TF-IDF	P@5 LSA	P@5 Híbrida
unigramas	2.251	6.97	0.5778	0.5778	0.5778	0.5778
unigramas + bigramas	5.726	13.03	0.6667	0.6444	0.7111	0.6889

Los bigramas mejoran las cuatro estrategias, a un costo de $2,5\times$ en vocabulario. Pero el resultado interesante es **cuál mejoran más**: BM25 y TF-IDF ganan alrededor de $+0,089$, mientras LSA y la híbrida ganan $+0,133$.

Y hay una **inversión de orden**: con unigramas solos LSA (0,556) queda por debajo de BM25 (0,578); con bigramas, LSA (0,689) le gana (0,667).

El valor del espacio latente depende de la granularidad de la representación. Con unigramas, *machine learning* y *learning machine* producen el mismo vector y el SVD no tiene estructura composicional que descubrir. Los bigramas le entregan unidades con significado propio, y ahí sí encuentra relaciones que el emparejamiento exacto no ve.

4 REPRESENTACIÓN VECTORIAL

Table 9: Propiedades de la representación vectorial

Propiedad	Valor
Documentos	594
Dimensión (vocabulario)	5.726
Unigramas	2.251
Bigramas	3.475
Celdas no nulas	71.187
Densidad	2.09%
Términos por documento	120
Formato de almacenamiento	Dispersa (dgCMatrix)

El esquema de pesado es **tf-idf con tf sublineal**:

$$w_{t,d} = (1 + \log f_{t,d}) \cdot \log \frac{N}{df_t}$$

seguido de normalización L_2 por fila, de modo que el producto punto entre dos filas es directamente el coseno. El tf sublineal evita que un término repetido veinte veces pese veinte veces más que uno que aparece una sola vez: la relevancia no crece linealmente con la frecuencia.

```
# La matriz nunca se densifica en ningun punto del pipeline
class(idx$tfidf)
```

```
## [1] "dgCMatrix"
## attr("package")
## [1] "Matrix"
```

```
dim(idx$tfidf)
```

```
## [1] 594 5726
```

```
sprintf("%.2f MB dispersa frente a %.0f MB densa",
        D$mb_tfidf_disperso, D$mb_tfidf_denso_teorico)
```

```
## [1] "0.84 MB dispersa frente a 26 MB densa"
```

Régimen $p \geq n$:

Hay casi diez veces más variables que observaciones: más de cinco mil dimensiones frente a menos de seiscientos documentos.

Esto explica dos hechos que reaparecen más adelante: la densidad del 2%, porque cada documento activa apenas un centenar de columnas, y el decaimiento extremadamente lento del espectro singular, porque cada documento aporta casi su propia dirección al espacio.

5 TIPO DE RECUPERACIÓN

Se implementaron cuatro estrategias que cubren los tres tipos contemplados en el enunciado: léxica, semántica e híbrida.

Table 10: Estrategias implementadas y su criterio de relevancia

Estrategia	Tipo	Espacio	Criterio de relevancia
BM25	Léxica	5.726 dims	Coincidencia de términos ponderada por rareza, con saturación de frecuencia y penalización por longitud.
TF-IDF + coseno	Léxica	5.726 dims	Orientación de los vectores: mide proporción de términos compartidos, no cantidad absoluta.
LSA	Semántica	200 componentes	Proximidad en un espacio latente donde los términos que coocurren quedan cerca.
Híbrida (RRF)	Fusión	—	Fusión de las posiciones que ocupa cada documento en BM25 y en LSA.

5.1 BM25

$$\text{score}(q, d) = \sum_{t \in q} \text{IDF}(t) \cdot \frac{f_{t,d}(k_1 + 1)}{f_{t,d} + k_1 \left(1 - b + b \frac{|d|}{\text{avgl}}\right)}$$

con $k_1 = 1.2$ y $b = 0.75$. La porción que **no** depende de la consulta está precalculada celda a celda dentro del índice, de modo que puntuar en tiempo de consulta se reduce a un producto matriz-vector sobre las columnas de los términos consultados.

5.2 TF-IDF con similitud coseno

Esta estrategia existe para **aislar el efecto de la reducción dimensional**. Comparte con LSA el mismo pesado y la misma medida de similitud, y difiere únicamente en el espacio donde opera. Cualquier diferencia de ranking entre ambas es por tanto atribuible a la reducción y a nada más.

Comparar LSA contra BM25 sería confuso para ese propósito, porque cambian dos cosas a la vez: el esquema de pesado **y** el espacio.

5.3 Fusión híbrida por Reciprocal Rank Fusion

$$\text{RRF}(d) = \sum_m \frac{1}{60 + \text{rango}_m(d)}$$

Opera sobre **posiciones**, no sobre puntajes, precisamente porque las escalas no son comparables: BM25 no está acotado y el coseno vive en $[-1, 1]$. Promediar esos números sería un error de tipos disfrazado de aritmética.

6 REDUCCIÓN DE DIMENSIONALIDAD

6.1 Método y proyección de la consulta

Se aplicó **Truncated SVD (LSA)** mediante `RSpectra::svds`, que calcula solo los k primeros valores y vectores singulares por iteración de Lanczos y **nunca densifica la matriz**.

$$X \approx U_k D_k V_k^\top$$

Los documentos viven en las filas de $XV_k = U_k D_k$, precalculadas y normalizadas dentro del índice. Una consulta q se proyecta al **mismo** espacio mediante la **misma** matriz V_k (*fold-in*):

$$\hat{q} = q^\top V_k$$

y el puntaje es el coseno contra las filas ya normalizadas.

```
# La consulta se proyecta con la misma V del SVD: k componentes, no el
# vocabulario completo. Es el requisito explicito del enunciado.
dim(idx$V)           # terminos x k
```

```
## [1] 5726 200
```

```
dim(idx$docs_lsa)    # documentos x k
```

```
## [1] 594 200
```

6.2 Elección del número de componentes

El criterio habitual, retener el k que alcance cierto porcentaje de varianza explicada, **no funciona aquí**. Vale la pena mostrar por qué en lugar de forzarlo.




Figure 2: Energía acumulada del espectro singular. El umbral convencional del 80 por ciento resulta inalcanzable.

Por qué se descartó el criterio de varianza:

El espectro de una matriz término-documento decae muy lentamente. Alcanzar el 80% de energía exigiría prácticamente rango completo, lo que anularía el propósito mismo de reducir.

Es consecuencia directa del régimen $p \geq n$ señalado antes: cada documento aporta una dirección casi propia.

El criterio adoptado es **rendimiento de recuperación**: se barrió k y se midió Precision@5 sobre el conjunto de evaluación.

Table 11: Barrido del número de componentes latentes

k	Energía (\%)	P@5	P@10	ms/consulta	V (MB)
25	14.8	0.4222	0.4111	56.1	1.09
50	22.5	0.6000	0.5111	53.4	2.18
100	35.2	0.6444	0.5111	52.6	4.37
150	45.9	0.7111	0.6111	52.0	6.55
200	55.2	0.7333	0.6556	55.9	8.74
250	63.5	0.6889	0.6000	53.1	10.92
300	70.9	0.7111	0.6222	51.7	13.11




Figure 3: Precision@5 de LSA en función de k . Máximo real en k igual a 200 y descenso posterior.

Existe un **máximo real** en $k = 200$ seguido de un descenso en $k = 250$ y $k = 300$. Es el comportamiento clásico de LSA: pasado cierto punto, los componentes adicionales capturan ruido en lugar de estructura semántica. La elección de $k = 200$ no es un desempate por parsimonia sino un óptimo medido.

6.3 Efecto sobre memoria y tiempo de respuesta

Table 12: Consumo de memoria por objeto del índice

Objeto	MB
TF-IDF disperso (original)	0.84
TF-IDF denso (hipotético)	26.00
Documentos en espacio LSA	0.91
Matriz de proyección V	8.74

Aquí aparece un resultado contraintuitivo que conviene señalar. La representación **de los documentos** sí se abarata drásticamente. Pero para poder proyectar consultas hay que conservar V , que **domina el tamaño del índice**.

La reducción abarata los documentos pero obliga a cargar el mapa término→espacio latente. Con 593 documentos ese intercambio no compensa en memoria; compensaría con decenas de miles, donde el costo fijo de V se amortiza sobre muchas más filas.

Table 13: Tiempo de respuesta medido en caliente sobre diez corridas

Estrategia	Milisegundos por consulta
bm25	60.3
tfidf	49.0
lsa	50.7
hibrido	56.1

La diferencia es menor de lo esperable: LSA no resulta más rápida que la búsqueda dispersa, porque el producto denso $593 \times k$ tiene un costo comparable al de recorrer las pocas columnas activas de una matriz con densidad del 2%.

7 MECANISMO DE RANKING

Cálculo del puntaje. Cada estrategia produce un vector de puntajes de longitud N . Los documentos se ordenan de mayor a menor y se corta en el top- n que elija el usuario, entre 5, 10 y 20. Solo se devuelven documentos con puntaje estrictamente positivo.

Qué significa un puntaje alto. En BM25, que el documento contiene términos raros de la consulta con frecuencia alta relativa a su longitud. En TF-IDF y LSA, que el vector del documento apunta en dirección parecida a la de la consulta: es una medida de proporción, no de cantidad. En la híbrida, que el documento quedó bien posicionado en ambos rankings simultáneamente.

Manejo de empates. Se resuelven por número de citas descendente y, si persisten, por fecha de publicación descendente.

Citas y fecha actúan solo como desempate:

El ranking principal proviene siempre de la representación numérica del texto. El enunciado descarta explícitamente ordenar únicamente por fecha, citas o descargas, y esos criterios nunca intervienen mientras los puntajes difieran.

Comparabilidad entre métodos. No la hay. BM25 no está acotado, el coseno vive en $[-1, 1]$ y RRF produce valores en torno a 0,03. La interfaz muestra una barra normalizada entre 0 y 1 **dentro** del conjunto devuelto, exclusivamente como ayuda visual, y advierte de forma explícita que no permite comparar entre estrategias.

8 INTEGRACIÓN EN LA APLICACIÓN

El módulo vive en la página **Buscador** de la aplicación del Taller 2, que conserva íntegras todas sus funcionalidades previas.

Table 14: Organización de archivos del sistema

Archivo	Rol
global.R	Tokenizador, léxico, corrector, carga del índice y las cuatro estrategias

ui.R	Página del buscador: campo, selector de estrategia y de top-n
server.R	Observadores, render de resultados y modos de comparación
pipeline.R	Todo el pipeline offline: índice, vocabulario, evaluación y pruebas
search_index.rds	Índice precalculado que consume la aplicación
resultados.rds	Tablas de resultados que consume este documento
juicios.csv	Juicios de relevancia, editados manualmente

Correspondencia garantizada entre documento y aplicación:

El tokenizador vive en `global.R` y `build_index.R` hace `source("global.R")`. El procesamiento de indexación es por tanto bit a bit el mismo que el de consulta.

El enunciado advierte que no se acepta documentar un método y utilizar otro distinto en el buscador. Esta estructura hace que la divergencia sea imposible por construcción, no por disciplina.

El índice se carga en `global.R` y no dentro de `server()`: cargarlo por sesión lo duplicaría por cada usuario conectado, mientras que en `global.R` se comparte entre todas las sesiones del proceso.

La interfaz ofrece además dos modos de comparación lado a lado: *BM25 frente a LSA* y una *ablación TF-IDF frente a LSA*, esta última con el pesado y la similitud fijos para que la única diferencia visible sea la reducción.

9 EVALUACIÓN DE RESULTADOS

9.1 Diseño experimental

Se definieron **10 consultas** que cubren los cinco tipos exigidos, con 176 pares consulta-documento juzgados manualmente.

Table 15: Consultas del conjunto de evaluación

ID	Consulta
Q1	large language models
Q2	systems that automatically create new text and images
Q3	artificial intelligence applications
Q4	federated learning privacy preservation
Q5	aprendizaje profundo para el diagnostico de enfermedades
Q6	cars that drive themselves without a human
Q7	protecting patient data when training models across hospitals
Q8	quantum computing for combinatorial optimization
Q9	deep learning
Q10	explainability methods that are not based on gradients

Metodología de pooling:

Los juicios se construyeron juzgando la **unión de los top-10** de las cuatro estrategias, no el corpus completo. Es la metodología con la que se construyen las colecciones de TREC.

Su sesgo conocido es que **subestima el recall**: un documento relevante que ningún sistema recuperó nunca llega a juzgarse. Por esa razón se reportan métricas de precisión en el tope del ranking y no Recall.

Los juicios son acumulativos: al cambiar la configuración del sistema, los ya emitidos se conservan aunque el documento salga del pool vigente.

9.2 Saturación del pool

Table 16: Proporción de documentos relevantes en el pool por consulta

Consulta	Juzgados	Relevantes	Proporción
Q1	21	21	1.00
Q2	15	4	0.27
Q3	33	29	0.88
Q4	11	8	0.73
Q5	16	14	0.88
Q6	21	3	0.14
Q7	20	4	0.20
Q8	10	0	0.00
Q9	13	13	1.00
Q10	16	7	0.44

Tres consultas no discriminan por construcción: **Q1** y **Q9** porque todo lo recuperado resultó relevante, y **Q8** porque **ninguno** lo fue. En Q8 las cuatro estrategias obtienen cero en todas las métricas, de modo que incluirla en el promedio no compara nada: solo arrastra las medias por igual. Siguiendo la práctica de TREC se reportan ambas versiones.

Que Q8, *quantum computing for combinatorial optimization*, carezca de documentos relevantes no es un fallo del sistema sino un hallazgo sobre el corpus: la revista no cubre ese tema en el periodo indexado.

9.3 Resultados por consulta

Table 17: Precision@5 por consulta y estrategia

consulta_id	bm25	tfidf	lsa	hibrido
Q1	1.0	1.0	1.0	1.0
Q2	0.4	0.4	0.2	0.4
Q3	1.0	1.0	1.0	1.0
Q4	0.8	0.6	0.8	0.8

Q5	1.0	0.8	1.0	1.0
Q6	0.2	0.4	0.4	0.4
Q7	0.4	0.4	0.4	0.4
Q8	0.0	0.0	0.0	0.0
Q9	1.0	1.0	1.0	1.0
Q10	0.6	0.6	0.8	0.6

Table 18: Promedios excluyendo Q8, que carece de documentos relevantes

Estrategia	P@5	P@10	MRR	nDCG@5
hibrido	0.7333	0.6222	0.9259	0.9191
lsa	0.7333	0.6556	0.9259	0.9202
bm25	0.7111	0.6444	0.9259	0.9221
tfidf	0.6889	0.6333	0.8704	0.8961

9.4 Hallazgo principal: el experimento Q4 frente a Q7

Q4 y Q7 expresan la **misma necesidad de información** con vocabularios distintos. Q4 emplea los términos técnicos (*federated learning privacy preservation*); Q7 los parafrasea sin usar ninguno de ellos (*protecting patient data when training models across hospitals*). Es un experimento controlado con una sola variable.

Table 19: Degradación ante desajuste de vocabulario con la necesidad de información fija

Estrategia	Q4 (técnica)	Q7 (parafraseada)	Caída
bm25	0.8	0.4	-0.4
lsa	0.8	0.4	-0.4
hibrido	0.8	0.4	-0.4
tfidf	0.6	0.4	-0.2

El emparejamiento léxico exacto es el que **más** se derrumba ante el desajuste de vocabulario. Es exactamente lo que la teoría predice, medido con una variable controlada.

9.5 Acuerdo entre estrategias

Table 20: Acuerdo entre pares de estrategias, promediado sobre las consultas

A	B	Jaccard@10	Kendall τ
bm25	lsa	0.528	0.203
tfidf	lsa	0.523	0.316
bm25	tfidf	0.673	0.456
tfidf	hibrido	0.636	0.496
bm25	hibrido	0.681	0.499

lsa	hibrido	0.715	0.558
-----	---------	-------	-------

BM25 y LSA muestran el menor acuerdo, con un τ de Kendall cercano a 0,30. Ordenan de forma muy distinta y aun así puntúan casi igual: rankings diferentes, calidad equivalente. Eso justifica conceptualmente la fusión híbrida, porque los errores de una no son los errores de la otra.

9.6 Análisis de un resultado poco relevante

La consulta **Q2**, *systems that automatically create new text and images*, describe modelos generativos sin emplear la palabra *generative*. Tras el procesamiento queda reducida a los stems **system**, **automat**, **creat**, **text** e **imag**, todos de baja capacidad discriminante en un corpus de inteligencia artificial.

Table 21: Primeros resultados de Q2: coincidencia literal sin coincidencia de intención

Pos.	Artículo recuperado	Puntaje
1	A computer graphics-based model to generate dynamic 3D ani	0.42728
2	Script identification in multilingual environment: a surve	0.42008
3	Decoding synthetic news: an interpretable multimodal frame	0.39778

Los artículos recuperados tratan sobre identificación de escritura multilingüe y generación de animaciones: coinciden con los términos literales pero no con la intención de la consulta.

Es el límite estructural del modelo de bolsa de palabras. Ni siquiera el espacio latente lo salva, porque esas cinco palabras coocurren con demasiados temas distintos como para definir una dirección semántica útil.

9.7 Interpretación de las diferencias

Table 22: Capacidad de cada consulta para separar a las estrategias

Consulta	Rango de P@5	Discrimina
Q1	0.0	No
Q2	0.2	Sí
Q3	0.0	No
Q4	0.2	Sí
Q5	0.2	Sí
Q6	0.2	Sí
Q7	0.0	No
Q8	0.0	No
Q9	0.0	No
Q10	0.2	Sí

Solo **5 de las 10 consultas** producen alguna diferencia entre estrategias, y en todas el rango es de 0,2, es decir, **un solo documento**. Con diez consultas esas brechas no son estadísticamente distinguibles.

Conclusión defendible:

No es que una estrategia sea mejor. Es que las cuatro rinden de forma equivalente en agregado, y que las diferencias interesantes aparecen **por tipo de consulta**, no en el promedio.

- BM25 lidera en MRR y nDCG: coloca el primer relevante más arriba.
- BM25 es también el más frágil ante paráfrasis, según el experimento Q4–Q7.
- LSA es más estable ante desajuste de vocabulario pero ordena peor en general.
- La híbrida gana por poco en P@5 sin dominar en ninguna otra métrica.

Que la reducción dimensional no mejore el ranking en agregado es un resultado válido, no un fracaso. Con 593 artículos de una sola revista sobre un solo tema, el vocabulario es homogéneo: casi no existe desajuste que el espacio latente pueda corregir. LSA rinde cuando el corpus es diverso y la gente nombra lo mismo de formas distintas. La consulta Q6, *cars that drive themselves* frente a *autonomous vehicles* en el corpus, puso a prueba precisamente esa hipótesis y las cuatro estrategias empataron.

10 LIMITACIONES Y TRABAJO FUTURO

1. **Modelo de bolsa de palabras.** No hay tratamiento de la negación: Q10, *explainability methods that are not based on gradients*, recupera precisamente lo que la consulta excluye. Tampoco hay orden de palabras más allá de los bigramas.
2. **El puente español-inglés es un léxico, no un traductor.** Opera token por token, de modo que pierde el orden de las expresiones compuestas y solo funciona a nivel de unigrama.
3. **Sesgo del pooling.** Subestima el recall real. Los juicios provienen de un único evaluador, sin medida de acuerdo entre anotadores.
4. **Escala del conjunto de evaluación.** Diez consultas y 176 juicios permiten detectar tendencias, no diferencias finas.
5. **Contaminación del campo keywords.** Mezcla palabras clave del autor con la taxonomía editorial de Springer. El filtro `max_df` neutraliza su efecto sobre el ranking, pero infla la longitud de los documentos, parámetro al que BM25 sí es sensible.
6. **Ponderación de campos por repetición.** Es una aproximación burda a BM25F, con el mismo efecto colateral sobre la longitud.

Como trabajo futuro razonable: incorporar *sentence embeddings* preentrenados como tercera representación, expansión de consultas por pseudo-realimentación de relevancia, juicios graduados en lugar de binarios, y un conjunto de evaluación de mayor tamaño que permita contrastes estadísticos.

11 REPRODUCIBILIDAD

Congelación de la configuración:

Los parámetros del sistema ($k = 200$, uso de bigramas, umbrales de poda) se fijaron **antes** de la evaluación final, con base en el barrido y la ablación.

Iterar sobre la configuración después de juzgar sesgaría el pool hacia lo que el sistema vigente recupera, y las métricas pasarían a medir cuánto se parece el sistema a sí mismo.