

TALLER 2: MINERÍA DE DATOS

Dashboard KDD — Nature Ecology & Evolution

Sebastián Tabares-Segovia

2026-06-07

Tabla de contenidos

1. Objetivo	1
2. Fuente de Datos	2
2.1. Base de datos del Taller 1	2
2.2. Estructura de la base de datos	2
2.3. Validación	2
3. Arquitectura de la Aplicación	3
3.1. Pestaña Dashboard	3
3.2. Pestaña Artículos	3
3.3. Pestaña Actualizar datos	3
3.4. Pestaña Metodología	3
4. Widgets Interactivos	3
5. Indicadores Descriptivos	4
6. Visualizaciones	4
6.1. Artículos por categoría temática	4
6.2. Evolución temporal de publicaciones	5
6.3. Distribución de citas	5
6.4. Top 10 autores más frecuentes	6
7. Funciones nuevas respecto al contenido de clase	6
8. Limitaciones	6
9. Conclusión	7

1. Objetivo

El objetivo de este taller es construir una aplicación interactiva en **Shiny (R)** que permita consultar, visualizar y actualizar la base de datos SQLite construida en el Taller 1, funcionando como un dashboard analítico orientado al proceso KDD visto en clase.

Etapas KDD	Implementación en la app
Recolección	API OpenAlex + scraping <code>rvest</code> sobre nature.com
Almacenamiento	Base de datos SQLite (<code>nature_eco_evo_2025.sqlite</code>)
Consulta	Filtros dinámicos construidos en SQL desde R
Visualización	4 gráficos interactivos con <code>highcharter</code>
Actualización	Botón de scraping para artículos nuevos (2026)

2. Fuente de Datos

2.1. Base de datos del Taller 1

La base de datos de entrada fue construida en el Taller 1 a partir de dos fuentes:

- **API de OpenAlex:** metadatos estructurados (título, autores, DOI, abstract, citas, referencias) para los 325 artículos de Nature Ecology & Evolution publicados en 2025.
- **Scraping de nature.com:** los *Accesses* (vistas totales) fueron extraídos del HTML estático de cada artículo con pausas aleatorias de 1.5–4 segundos.

2.2. Estructura de la base de datos

Tabla papers (325 registros, 14 columnas):

Columna	Tipo	Fuente
<code>paper_id</code>	TEXT PK	OpenAlex
<code>journal_name</code>	TEXT	Fijo
<code>title</code>	TEXT	OpenAlex
<code>publication_date</code>	TEXT	OpenAlex
<code>year</code>	INTEGER	OpenAlex
<code>doi</code>	TEXT	OpenAlex
<code>url</code>	TEXT	Construida del DOI
<code>abstract</code>	TEXT	OpenAlex (índice invertido)
<code>authors_raw</code>	TEXT	OpenAlex
<code>n_authors</code>	INTEGER	Conteo
<code>citations</code>	INTEGER	OpenAlex
<code>downloads</code>	INTEGER	Scraping nature.com
<code>n_references</code>	INTEGER	OpenAlex
<code>topic_label</code>	TEXT	Clasificación por palabras clave

Tabla paper_references (14.981 registros): pares `paper_id` / `reference_id`.

2.3. Validación

Tabla 3: Validación de la base de datos

Tabla	Registros	Nulls_título	Con_Accesses
<code>papers</code>	373	0	324
<code>paper_references</code>	14981	NA	NA

3. Arquitectura de la Aplicación

La aplicación se desarrolló en un único archivo `app.R` con el framework **Shiny** y tema `flatly` de `bslib`. Está organizada en cuatro pestañas.

3.1. Pestaña Dashboard

- **Encabezado personalizado:** el navbar incluye logos institucionales, título del dashboard, nombre del autor y correo.
- **6 tarjetas de indicadores:** actualizadas dinámicamente según filtros.
- **2 tarjetas de hallazgos:** artículo más citado y con más Accesses, con hipervínculo al DOI.
- **4 gráficos highcharter:** cada uno responde al clic mostrando un modal con los artículos del subconjunto seleccionado.

3.2. Pestaña Artículos

Tabla `DT::datatable` con título (hipervínculo), autores, fecha, tema, DOI, citas y Accesses. Incluye filtros por columna y descarga CSV.

3.3. Pestaña Actualizar datos

Flujo de scraping al presionar el botón:

1. Recupera la fecha del último artículo en la BD.
2. Consulta OpenAlex por artículos posteriores a esa fecha.
3. Filtra duplicados.
4. Si hay nuevos: clasifica, scrapea Accesses y guarda en SQLite.
5. Si no hay nuevos: actualiza citas de los últimos 5 artículos.
6. Log con timestamp de cada paso.

3.4. Pestaña Metodología

Descripción del pipeline KDD, tabla de funciones nuevas y metadata de la base de datos.

4. Widgets Interactivos

Widget	Función Shiny	Pestaña
Selector de rango de fechas	<code>dateRangeInput()</code>	Dashboard, Artículos
Selección múltiple de categorías	<code>checkboxGroupInput()</code>	Dashboard
Lista desplegable	<code>selectInput()</code>	Artículos
Búsqueda por título	<code>textInput()</code>	Dashboard, Artículos
Búsqueda por autor	<code>textInput()</code>	Dashboard, Artículos
Filtro por DOI	<code>textInput()</code>	Dashboard
Botón aplicar / limpiar filtros	<code>actionButton()</code>	Dashboard
Botón de scraping	<code>actionButton()</code>	Actualizar
Botón descarga CSV	<code>downloadButton()</code>	Artículos, Modal
Tabla interactiva principal	<code>DT::datatable()</code>	Artículos
Tabla modal (clic en gráfico)	<code>DT::datatable()</code>	Dashboard

Total: **11 tipos de widgets**, superando el mínimo de 3 requerido.

5. Indicadores Descriptivos

Tabla 5: Indicadores descriptivos del dashboard

Indicador	Valor
Total artículos	373
Promedio autores/paper	8.9
Promedio citas/paper	3.7
Promedio referencias/paper	48.7
Papers con Accesses	324
Artículo más citado	Restoration cannot be scaled up globally to save r... (41 citas)
Artículo con más Accesses	Shotgun sequencing of airborne eDNA achieves rapid... (48,000 Accesses)

6. Visualizaciones

6.1. Artículos por categoría temática




Figura 1: Distribución temática de los 325 artículos

Otros domina con el 96.5 % del total. Los artículos de ML e IA Generativa representan el 0.8 %.

6.2. Evolución temporal de publicaciones




Figura 2: Publicaciones mensuales — Nature Ecology & Evolution 2025

Mes pico: **2025-07** (46 artículos). Media: 21.9 · Varianza: 134.9 · DE: 11.6 artículos/mes.

6.3. Distribución de citas




Figura 3: Histograma de citas por artículo. Línea azul: mediana.

Mediana: 1 · Media: 3.7 · Varianza: 33.1 · DE: 5.8. El 37.8% sin citas aún.

6.4. Top 10 autores más frecuentes




Figura 4: Top 10 autores con mayor número de artículos

7. Funciones nuevas respecto al contenido de clase

Función	Paquete	Justificación
<code>hchart()</code> , <code>highchart()</code> , <code>renderHighchart()</code> , <code>highchartOutput()</code>	<code>highcharter</code>	Requerido por enunciado sección 2.1.5. Clase 11 menciona <code>plotly</code> como alternativa.
<code>resp_body_json()</code>	<code>httr2</code>	Hermana de <code>resp_body_html()</code> para respuestas JSON de OpenAlex.
<code>dbWriteTable()</code>	<code>DBI</code>	Inserción masiva de data frame en SQLite.
<code>dbExecute()</code>	<code>DBI</code>	<code>UPDATE</code> desde R para actualizar citas.
<code>downloadHandler()</code>	<code>shiny</code>	Descarga de tablas filtradas y selecciones del modal en formato CSV.
<code>downloadHandler()</code>	<code>shiny</code>	Permite exportar en CSV tanto la tabla general como los subconjuntos seleccionados desde los gráficos.
<code>JS()</code>	<code>htmlwidgets</code>	Click handlers en JavaScript para eventos <code>highcharter</code> → Shiny.

8. Limitaciones

- **Variable downloads:** se utilizó la métrica de *Accesses* de nature.com como equivalente, aceptada por el enunciado (sección 6.1 del Taller 1).
- **Artículos sin abstract:** los artículos *News & Views* y *Correspondence* no tienen abstract en OpenAlex, afectando la clasificación temática.
- **Clasificación por palabras clave:** puede subestimar artículos con terminología muy especializada fuera de los diccionarios definidos.

9. Conclusión

Este taller implementó el ciclo completo del proceso KDD sobre los artículos de Nature Ecology & Evolution 2025. La app demuestra cómo las decisiones de la fase de recolección condicionan las posibilidades de análisis posteriores. La funcionalidad de clic interactivo en los gráficos, que abre un modal con los artículos del subconjunto y sus estadísticas descriptivas, representa la integración más sofisticada del taller: conecta la visualización de alto nivel con el acceso granular a los datos en una sola interacción.