

TALLER 4: MINERÍA DE DATOS

Sistema de recuperación de información — Nature Ecology & Evolution

Sebastián Tabares-Segovia

30 Julio 2026

Índice

1. Objetivo	1
2. Construcción del corpus	2
3. Procesamiento del texto	2
4. Representación vectorial	3
5. Tipo de recuperación	4
6. Reducción de dimensionalidad	4
7. Mecanismo de ranking	5
8. Integración en la aplicación	6
9. Evaluación de los resultados	6
10. Consideraciones computacionales	7
11. Consultas	7
12. Conclusión	9

1. Objetivo

Este taller amplía el dashboard construido en el Taller 2 con un **sistema de recuperación de información** que permite escribir una consulta en lenguaje natural y obtener los artículos de *Nature Ecology & Evolution* ordenados por relevancia. Se implementan y comparan **dos estrategias**: una recuperación **léxica** (TF-IDF disperso + similitud coseno) y una recuperación **semántica reducida** (LSA / Truncated SVD sobre el TF-IDF + coseno). Al menos uno de los rankings, el semántico, se construye sobre una representación de dimensión reducida, y la consulta del usuario se proyecta al mismo espacio latente antes de calcular la similitud.

Componente	Decisión
Corpus	<code>title</code> + <code>abstract</code> (si existe) + <code>topic_label</code>
Procesamiento	minúsculas, letras/guion, <i>stopwords</i> EN, <i>stemming</i> Porter
Representación	TF-IDF disperso, unigramas + bigramas
Reducción	Truncated SVD (LSA), $k = 200$
Similitud	Coseno
Estrategias	Léxica (TF-IDF) vs. Semántica (LSA)

El índice se precalcula una sola vez con `build_index.R` (objeto `search_index.rds`) y la aplicación **no** lo reconstruye en cada búsqueda.

2. Construcción del corpus

Cuadro 2: Estado del corpus

Aspecto	Valor
Artículos totales	373
Sin título	0
Con resumen (abstract)	75
Sin resumen	298
Sin autores	29
Campo de palabras clave	No disponible en la base

Campos utilizados. Cada artículo se representa concatenando su **título**, su **resumen** cuando está disponible y su **etiqueta temática** (`topic_label`) cuando es informativa (distinta de *Otros*). La base **no** contiene un campo de palabras clave, por lo que no se utiliza; el enunciado lo contempla como opcional (“cuando estén disponibles”).

Número de artículos. Se incluyen los 373 artículos de la base. De ellos, solo 75 (20.1 %) tienen resumen; los 298 restantes corresponden mayoritariamente a formatos *News & Views*, *Correspondence* y correcciones editoriales que en OpenAlex no exponen abstract. Esta es la limitación central del corpus: **la mayoría de documentos se representa únicamente con su título**, un texto corto (media de 72 caracteres).

Tratamiento de faltantes. No se reemplaza ningún texto ausente por contenido inventado. Un resumen faltante simplemente **no aporta tokens** al documento; el artículo sigue siendo recuperable por su título. Los autores faltantes (29) solo afectan la visualización, no el ranking.

Idioma. *Nature Ecology & Evolution* publica íntegramente en inglés; se verificó por muestreo que títulos y resúmenes están en ese idioma, por lo que el procesamiento se configura para inglés (*stopwords* y *stemming* en inglés).

Criterios de inclusión/exclusión. Se incluyen todos los artículos con título no vacío (el 100 %). No se excluye ningún documento: incluso los que solo tienen título aportan señal léxica útil.

3. Procesamiento del texto

```
en_stop <- stopwords::stopwords("en")

prep_txt <- function(x) {                                # normalización
  x <- tolower(x)
  x <- gsub("[^a-z -]", " ", x)                          # conserva letras y guion (deep-sea)
```

```

  trimws(gsub("\\s+", " ", x))
}

tok_txt <- function(x) {
  # tokenización + limpieza
  lapply(text2vec::word_tokenizer(x), function(w) {
    w <- w[nchar(w) >= 3] # descarta tokens muy cortos
    w <- w[!w %in% en_stop] # elimina stopwords
    SnowballC::wordStem(w, language = "en") # stemming Porter
  })
}

```

Las decisiones de procesamiento y su justificación:

Operación	Decisión	Justificación
Minúsculas	Sí	Une <i>Climate</i> y <i>climate</i> en un mismo término.
Normalización	Solo letras y guion	Elimina números/puntuación pero conserva términos científicos con guion (<i>deep-sea</i> , <i>coral-eating</i>).
<i>Stopwords</i> (EN)	Se eliminan	Palabras como <i>the</i> , <i>of</i> , <i>and</i> no discriminan documentos.
<i>Stemming</i> Porter	Sí	Agrupar <i>restoration/restore/restoring</i> → una raíz; reduce el vocabulario.
Lematización	No	El <i>stemming</i> es suficiente y más liviano; evita dependencias pesadas.
Números	Se eliminan	Aportan poco a la similitud temática en este corpus.
<i>n</i> -gramas	Unigramas + bigramas	Los bigramas capturan conceptos (<i>coral reef</i> , <i>climate change</i>) que los unigramas fragmentan.

Se privilegió un procesamiento liviano y reproducible: *stemming* en lugar de lematización, y sin POS-tagging ni NER, porque para una tarea de recuperación por similitud el costo de esas etapas no compensa la mejora marginal.

4. Representación vectorial

```

# doc = título + abstract (si existe) + tema (si informativo)
construir_doc <- function(ti, ab, tp) {
  d <- ti
  if (!is.na(ab) && nchar(trimws(ab)) > 0) d <- paste(d, ab)
  if (!is.na(tp) && tp != "Otros") d <- paste(d, tp)
  d
}

papers$doc <- mapply(construir_doc, papers$title, papers$abstract, papers$topic_label)

crear_it <- function() itoken(papers$doc, preprocessor = prep_txt,
                             tokenizer = tok_txt, ids = papers$paper_id,
                             progressBar = FALSE)

vocab <- create_vocabulary(crear_it(), ngram = c(1L, 2L)) |>
  prune_vocabulary(term_count_min = 2L, doc_proportion_max = 0.60)
vectorizer <- vocab_vectorizer(vocab)

dtm <- create_dtm(crear_it(), vectorizer)
tfidf <- TfIdf$new(norm = "l2", sublinear_tf = TRUE)

```

```
dtm_tfidf <- as(fit_transform(dtm, tfidf), "CsparseMatrix")
dim_orig <- ncol(dtm_tfidf)
densidad <- 100 * length(dtm_tfidf@x) / prod(dim(dtm_tfidf))
```

Se eligió **TF-IDF** por ser la representación estándar para recuperación léxica (Clase 23): pondera cada término por su frecuencia en el documento (TF) y penaliza los términos ubicuos mediante el IDF, de modo que las palabras discriminativas dominan el vector. Se usa TF sublineal ($1 + \log tf$) para amortiguar repeticiones y normalización L_2 para que la similitud coseno se reduzca a un producto punto.

Propiedad	Valor
Dimensión (vocabulario)	2.294 términos
Matriz documento-término	373×2.294
Tipo	Dispersa (dgCMatrix)
Densidad	1.02 %
Poda de vocabulario	término en ≥ 2 docs; se ignora si aparece en $> 60\%$

Ventajas: interpretable (cada dimensión es un término), muy eficiente en memoria por la dispersión, sin necesidad de entrenamiento ni de modelos externos. **Limitaciones:** no captura sinonimia ni polisemia (dos documentos sobre el mismo tema con vocabulario distinto tendrán similitud baja); es la motivación para la segunda estrategia.

5. Tipo de recuperación

Se implementan las dos primeras familias vistas en clase:

- **Léxica (TF-IDF + coseno):** un artículo es relevante si comparte términos con la consulta. La similitud coseno compara la **orientación** de los vectores (no su magnitud), premiando la coincidencia de términos ponderados por IDF.
- **Semántica reducida (LSA + coseno):** artículos y consulta se comparan dentro de un **espacio latente** de k dimensiones obtenido por Truncated SVD. Documentos que comparten *temas* (aunque no términos exactos) quedan cercanos, lo que mitiga la sinonimia.

No se implementa una estrategia híbrida como ranking principal, aunque el diseño la permitiría combinando ambos puntajes; se prioriza el contraste limpio léxico-semántico que pide el enunciado.

6. Reducción de dimensionalidad

```
k <- min(200L, ncol(dtm_tfidf) - 1L, nrow(dtm_tfidf) - 1L)
svd <- irlba(dtm_tfidf, nv = k) # Truncated SVD (disperso)

## Warning in irlba(dtm_tfidf, nv = k): You're computing too large a percentage of
## total singular values, use a standard svd instead.

var_expl <- cumsum(svd$d^2) / sum(dtm_tfidf^2) # varianza acumulada
doc_lsa <- as.matrix(dtm_tfidf %*% svd$v) # documentos en  $R^k$ 
doc_lsa <- doc_lsa / pmax(sqrt(rowSums(doc_lsa^2)), 1e-12) # L2
```

Método. Truncated SVD sobre la matriz TF-IDF dispersa (LSA). Se aplica con `irlba`, que calcula solo los k primeros valores/vectores singulares **sin densificar** la matriz, cumpliendo la restricción de memoria.




Figura 1: Varianza acumulada explicada por el número de componentes (Truncated SVD).

Aspecto	Valor
Dimensión original	2.294
Dimensión reducida (k)	200
Factor de compresión	$11.5\times$
Varianza acumulada en k	79.9%

Criterio para k . Se fijó $k = 200$ como el menor valor que conserva $\geq 75\%$ de la varianza (línea morada en la figura), equilibrando fidelidad y compresión. Con $k = 100$ se retiene 52% y con $k = 150$, 68%.

Proyección de la consulta. Como $X \approx UDV^\top$, un documento en el espacio latente es XV . La consulta se proyecta con la **misma** matriz V : $q_{\text{lsa}} = q_{\text{tfidf}}V$, y luego se normaliza. Así consulta y documentos viven en el mismo $\mathbb{R}^k$ (función `buscar_semantico` en `search_engine.R`).

Información conservada/perdida. Se conservan las direcciones de máxima covariación término-documento (los “temas” latentes) y se descartan los ejes de baja varianza, que suelen ser ruido y términos idiosincráticos. El costo es la **interpretabilidad**: las dimensiones latentes ya no son términos individuales.

7. Mecanismo de ranking

- **Puntaje.** Similitud coseno en $[0, 1]$: en la estrategia léxica, producto punto de vectores TF-IDF L_2 -normalizados; en la semántica, coseno en el espacio LSA. Un puntaje alto significa mayor alineación temática con la consulta.
- **Orden.** Descendente por puntaje.
- **Empates.** Se rompen por número de **citas** y luego por **fecha más reciente** (criterios *secundarios*, nunca principales), como se implementa en `.armar_resultados`.
- **Comparabilidad.** Los puntajes de las dos estrategias **no** son directamente comparables: aunque ambos son cosenos en $[0, 1]$, provienen de espacios distintos (términos vs. latente) y el coseno en LSA tiende a ser sistemáticamente mayor. Solo se comparan *rankings*, no valores absolutos.

El ranking principal se construye a partir de la representación numérica del texto; los filtros SQL del Taller 2 se conservan como apoyo, pero **no** determinan la relevancia.

8. Integración en la aplicación

El buscador se añadió como una nueva pestaña “**Buscador**” en `app.R`, conservando intactas las cuatro pestañas del Taller 2. La integración sigue estas reglas:

1. `build_index.R` construye el índice (TF-IDF + LSA + metadatos) y lo guarda en `search_index.rds`.
2. `app.R` carga el índice **una sola vez** al iniciar (`readRDS`) y comparte las funciones de `search_engine.R`.
3. Cada búsqueda solo vectoriza la consulta y calcula productos matriciales: no reconstruye la matriz, no reentrena el SVD ni reprocesa el corpus.

Las estrategias del documento y de la app son **las mismas** funciones (`buscar_lexico`, `buscar_semantico`), por lo que no hay discrepancia entre lo documentado y lo implementado. El usuario elige la estrategia, el número de resultados (5/10/20) y puede ver ambas en paralelo.

9. Evaluación de los resultados

Se definieron cinco consultas sobre el contenido real de la revista, cubriendo las categorías exigidas. La relevancia de cada artículo se juzgó manualmente y se codificó mediante términos de relevancia sobre el título, de modo que la métrica sea reproducible.

Cuadro 6: **Precision@5** por consulta y estrategia

Categoría	Consulta	P@5 TF-IDF	P@5 LSA
Términos directos	coral reef restoration and degrada	1.00	1.00
Sinónimos/relacionados	global warming effects on species	0.80	0.80
General	climate change	1.00	1.00
Específica	generative artificial intelligence	0.20	0.20
Léxica vs. semántica	deep sea mining microbial communit	0.80	0.80

En promedio, TF-IDF alcanza **P@5 = 0.76** y LSA **P@5 = 0.76**. En un corpus pequeño y dominado por títulos cortos, ambas estrategias coinciden en la *cabeza* del ranking para consultas con términos directos (coral, climate), donde la coincidencia léxica ya es muy informativa.

Cuadro 7: Comparación de rankings — ‘deep sea mining microbial communities recovery’

Ranking	TF-IDF (léxica)	LSA (semántica)
1	Assessing mining impacts in the deep sea	Assessing mining impacts in the deep sea
2	Impacts of an industrial deep-sea mining tri	Impacts of an industrial deep-sea mining tri
3	Mines aren’t on the maps	Mines aren’t on the maps
4	Community conservatism is widespread across	Community conservatism is widespread across
5	Collective dynamical regimes predict invasio	Deep-sea-floor diversity in Asteroidea is sh

Diferencias entre rankings. En la consulta “*deep sea mining microbial communities recovery*”, ambas estrategias devuelven prácticamente el mismo top-5 y solo difieren en la quinta posición: la estrategia semántica promueve un artículo temáticamente cercano al fondo marino (*Deep-sea-floor diversity...*) en lugar del que elige la léxica. Es un reordenamiento sutil de la cola del ranking hacia documentos del mismo tema, que no llega a modificar la **Precision@5**. En un corpus pequeño y dominado por títulos, la señal léxica ya captura casi toda la relevancia, así que el espacio latente reordena en los márgenes más que recuperar documentos nuevos.

Análisis de un resultado poco relevante. La consulta *específica* de IA generativa es el caso de peor desempeño (**P@5** bajo en ambas estrategias): el corpus contiene un único artículo verdaderamente sobre IA

generativa (*Generative AI as a tool to accelerate the field of ecology*), y el término genérico *ecology* arrastra editoriales generales de la revista al top. Es una limitación del **corpus** (cobertura temática), no del método: ninguna estrategia puede recuperar documentos relevantes que no existen.

Conclusión de la comparación. Sobre este corpus, LSA no supera a TF-IDF en [Precision@5](#) promedio y produce rankings muy similares, con diferencias limitadas al reordenamiento de las últimas posiciones hacia documentos temáticamente relacionados, a costa de perder interpretabilidad. La ventaja semántica sería mayor en un corpus con resúmenes completos, donde la sinonimia y la polisemia pesan más y el emparejamiento exacto de términos resulta insuficiente.

10. Consideraciones computacionales

```
## Warning in prettyNum(.Internal(format(x, trim, digits, nsmall, width, 3L, :
## 'big.mark' y 'decimal.mark' son ambos '.', lo cual puede ser confuso
```

Cuadro 8: Consumo de recursos del índice

Recurso	Valor
Documentos	373
Vocabulario	2.294
Dim. reducida (k)	200
Densidad TF-IDF	1.02 %
Tamaño del índice en RAM	4.89 MB

El índice completo ocupa alrededor de 4.9 MB en memoria, muy por debajo del límite de 16 GB. Las decisiones que controlan el consumo: matriz **dispersa** para TF-IDF, poda de vocabulario (términos raros y ubicuos), Truncated SVD **sin densificar** vía `irlba`, y **precálculo** del índice en disco (`search_index.rds`) para que la app no repita trabajo. No se usan modelos neuronales grandes ni API de pago.

11. Consultas

Cuadro 9: [Precision@5](#) por consulta y estrategia

Categoría	Consulta	P@5 TF-IDF	P@5 LSA
Términos directos	coral reef restoration and degradation	1.00	1.00
Sinónimos/relacionados	global warming effects on species diversity loss	0.80	0.80
General	climate change	1.00	1.00
Específica	generative artificial intelligence large language models ecology	0.20	0.20
Léxica vs. semántica	deep sea mining microbial communities recovery	0.80	0.80
Promedio		0.76	0.76

Evaluación cuantitativa ([Precision@5](#)). Se definieron cinco consultas sobre el contenido real de la revista, una por cada categoría exigida (términos directos, sinónimos, general, específica y una de fallo). Para cada consulta se ejecutaron las dos estrategias y se calculó la precisión entre los primeros cinco resultados, usando juicios de relevancia reproducibles basados en términos del título.

Ambas estrategias obtienen la **misma precisión promedio**, **P@5 = 0,76**. Las consultas de *términos directos* (“coral reef restoration...”) y *general* (“climate change”) alcanzan **P@5 = 1,00**: todos los resultados del top-5 son relevantes, porque la coincidencia léxica ya es muy informativa cuando la consulta usa el

vocabulario propio del corpus. Las consultas de *sinónimos* y de *minería en aguas profundas* obtienen 0,80 (un resultado no relevante entre los cinco). La consulta *específica* de inteligencia artificial generativa es el caso de peor desempeño, con $P@5 = 0,20$ en ambas estrategias.

La conclusión cuantitativa es que, sobre este corpus, la reducción semántica (LSA) **no mejora la precisión promedio frente a TF-IDF**. Esto es esperable: con 373 documentos representados en su mayoría por títulos cortos, la señal léxica ya captura casi toda la relevancia, y el espacio latente no aporta precisión adicional en el top-5. El bajo valor de la consulta de IA generativa no refleja una falla del método, sino una limitación de cobertura del corpus: contiene un único artículo genuinamente sobre el tema, y ninguna estrategia puede recuperar documentos relevantes que no existen.

Cuadro 10: Top-5 por consulta y estrategia («(rel)» = artículo relevante)

Consulta	#	TF-IDF (léxica)	LSA (semántica)
Términos directos	1	Protecting existing coral reefs (rel)	A control theory framework and i (rel)
	2	A control theory framework and i (rel)	Protecting existing coral reefs (rel)
	3	Quantifying coral reef-ocean int (rel)	Quantifying coral reef-ocean int (rel)
	4	Restoration cannot be scaled up (rel)	Restoration cannot be scaled up (rel)
	5	Author Correction: Restoration c (rel)	Author Correction: Restoration c (rel)
Sinónimos/relacionados	1	Threat reduction must be coupled (rel)	Threat reduction must be coupled (rel)
	2	Three-and-a-half million years o	Warming threatens soil health (rel)
	3	Warming threatens soil health (rel)	Three-and-a-half million years o
	4	Climate warming fuels the global (rel)	Climate warming fuels the global (rel)
	5	Global hotspots of butterfly div (rel)	Loss of macroevolutionary specie (rel)
General	1	Dispersal under climate change (rel)	Dispersal under climate change (rel)
	2	Adaptability to climate change i (rel)	Adaptability to climate change i (rel)
	3	Global dependency of canopy heig (rel)	Global dependency of canopy heig (rel)
	4	Vulnerability of soil food webs (rel)	Vulnerability of soil food webs (rel)
	5	Geographic redistributions are i (rel)	Geographic redistributions are i (rel)
Específica	1	Generative AI as a tool to accel (rel)	Generative AI as a tool to accel (rel)
	2	The next generation of colour pa	The next generation of colour pa
	3	Rigorous validation of ecologica	The many flavours of ecology
	4	Lasting effects of losing large	Lasting effects of losing large
	5	The many flavours of ecology	Rigorous validation of ecologica
Léxica vs. semántica	1	Assessing mining impacts in the (rel)	Assessing mining impacts in the (rel)
	2	Impacts of an industrial deep-se (rel)	Impacts of an industrial deep-se (rel)
	3	Mines aren't on the maps	Mines aren't on the maps
	4	Community conservatism is widesp (rel)	Community conservatism is widesp (rel)
	5	Collective dynamical regimes pre (rel)	Deep-sea-floor diversity in Aste (rel)

Comparación cualitativa de los rankings. Para entender el comportamiento detrás de las cifras se listaron los cinco primeros resultados de cada estrategia, marcando los artículos considerados relevantes. La observación general es que **ambas estrategias producen rankings muy similares**, con diferencias limitadas al reordenamiento de las últimas posiciones.

En las consultas de *términos directos*, *general* y *minería en aguas profundas*, las dos estrategias coinciden en el conjunto de artículos recuperados y solo intercambian el orden de algunas posiciones; en el caso de minería, tanto TF-IDF como LSA sitúan en el top-5 el estudio de impactos y el del ensayo industrial en aguas profundas. La única diferencia aparece en la quinta posición, donde la estrategia semántica promueve un artículo temáticamente cercano al fondo marino (“Deep-sea-floor diversity...”) en lugar del que elige la estrategia léxica. Es un efecto sutil de la representación latente —favorecer documentos del mismo tema— que no llega a modificar la [Precision@5](#).

La consulta de *inteligencia artificial generativa* es el resultado poco relevante analizado en detalle: ambas estrategias ubican correctamente en el primer lugar el único artículo del corpus realmente dedicado al tema (“Generative AI as a tool...”), pero las cuatro posiciones restantes las ocupan editoriales y artículos generales de ecología, arrastrados por el término genérico *ecology* de la consulta. Esto confirma que la limitación es del corpus y no del mecanismo de recuperación.

En síntesis, sobre este corpus pequeño y dominado por títulos, la recuperación semántica reordena de forma leve la cola del ranking hacia documentos temáticamente relacionados, sin cambios drásticos frente a la recuperación léxica. Una ventaja semántica más marcada sería esperable en un corpus con resúmenes completos, donde la sinonimia y la polisemia pesan más y el emparejamiento exacto de términos resulta insuficiente.

12. Conclusión

Se amplió el dashboard del Taller 2 con un sistema de recuperación que transforma los textos de SQLite en representaciones vectoriales (TF-IDF disperso y su reducción latente LSA), proyecta la consulta al mismo espacio y ordena los artículos por similitud coseno. Las dos estrategias implementadas —léxica y semántica reducida— coinciden en la cabeza del ranking en consultas directas y se separan en consultas donde la sinonimia importa, donde LSA recupera documentos que el método léxico omite. La principal restricción no es metodológica sino del corpus: con solo el 20 % de los artículos con resumen, buena parte de la señal proviene de títulos cortos, lo que acota el techo de desempeño de cualquier método. El diseño precalculado mantiene la aplicación liviana y reproducible, integrando de forma coherente lo documentado y lo implementado.