

Taller 3 - Minería de Datos

Predicción de trastornos de ansiedad (CID F41) y estimación de costo asociado

Daniel Eduardo Amarillo Echeverry

2026-07-05

Contents

1	Introducción y objetivo	2
1.1	Enfermedad seleccionada	2
2	Comprensión y calidad de los datos	2
2.1	Inconsistencias identificadas	2
2.2	Estrategia de tratamiento	3
3	Construcción de variables a nivel de beneficiario	3
4	Análisis descriptivo	4
5	Modelamiento predictivo	5
5.1	Estrategia general	5
5.2	Regresión logística	6
5.3	XGBoost	7
5.4	Random Forest	8
5.5	Comparación de modelos	9
6	Interpretación de resultados	9
6.1	Por qué la regresión logística falló y los ensambles no	9
6.2	Variables más influyentes	9
6.3	Análisis de errores y limitaciones del modelo	9
7	Estimación del costo asociado a la enfermedad	10
7.1	Definición de la unidad de análisis	10
7.2	Análisis descriptivo del costo	10
7.3	Modelo de costo	10
7.3.1	Evaluación y el trade-off sesgo-varianza	11

7.4	Intento de modelo en dos partes	12
7.5	Costo esperado bajo distintos perfiles	12
8	Conclusiones, limitaciones y trabajos futuros	12

1 Introducción y objetivo

Este informe documenta el desarrollo completo del Taller 3 de Minería de Datos, aplicado a la base real de utilización de servicios de salud proporcionada para el curso. El objetivo fue seleccionar una condición clínica identificable por código CID, construir una variable objetivo binaria a nivel de beneficiario, entrenar y comparar modelos de clasificación, interpretar sus resultados y estimar el costo esperado asociado a la enfermedad.

A lo largo del trabajo se tomaron numerosas decisiones metodológicas —de limpieza, de especificación de modelos y de tratamiento de problemas numéricos— que se documentan explícitamente en cada sección, junto con su justificación, siguiendo el espíritu del enunciado de que “todas las decisiones tomadas [...] deberán ser documentadas y justificadas”.

1.1 Enfermedad seleccionada

Se seleccionó **ansiedad**, identificada mediante los códigos CID pertenecientes al grupo **F41** (Otros trastornos de ansiedad), de acuerdo con la Clasificación Internacional de Enfermedades (CIE-10/ICD-10) de la OMS. La elección se registró en la planilla compartida del curso para evitar duplicidad con otros compañeros.

```
db_2026$CID <- str_squish(db_2026$CID)

anx <- db_2026[c("CHAVE_FUNCIONAL", "CID")] |>
  filter(str_detect(CID, "F41\\.*"))

pc_anx <- unique(anx$CHAVE_FUNCIONAL)

db_2026$ANSIEDADE <- as.integer(db_2026$CHAVE_FUNCIONAL %in% pc_anx)
table(db_2026$ANSIEDADE)
```

Siguiendo la regla de construcción de la variable objetivo indicada en el enunciado, **todo beneficiario con al menos una transacción cuyo CID pertenezca al grupo F41 recibe la etiqueta 1**; el resto recibe 0. Esto arrojó **419 beneficiarios positivos** de un total de **653,631**, es decir, una prevalencia de apenas **0.064%**. Esta cifra es el dato más importante de todo el taller, porque condiciona prácticamente cada decisión posterior: qué métricas usar, cómo tratar el desbalance, y cómo interpretar el desempeño de los modelos.

2 Comprensión y calidad de los datos

2.1 Inconsistencias identificadas

Durante la exploración inicial se confirmó que la base, al ser real, efectivamente presenta los problemas de calidad que anticipaba el enunciado:

- **Beneficiarios con más de un sexo registrado** en distintas transacciones (por ejemplo, un mismo CHAVE_FUNCIONAL apareciendo como “M” en un registro y como otro valor en otro).

- **Beneficiarios con más de un TIPO_BENEFICIARIO** a lo largo de su historial.
- **Fechas de nacimiento inválidas:** existen beneficiarios cuya fecha de nacimiento implicaría una edad de 120 años o más, o incluso posterior al año 2026, lo cual es físicamente imposible.
- **Categorías mal codificadas:** valores equivalentes escritos de forma distinta (p. ej. "MASCULINO" vs "M", o "MAE"/"FILHO" como variantes de "TITULAR"/"DEPENDENTE").
- **Valores faltantes:** sexo y tipo de beneficiario “No informado” en una proporción menor pero no despreciable de registros, y 302 beneficiarios sin fecha de nacimiento válida (edad faltante).

2.2 Estrategia de tratamiento

Para resolver el problema de “un beneficiario, múltiples valores”, se decidió usar la **moda** de cada variable categórica dentro de cada CHAVE_FUNCIONAL en lugar de simplemente tomar el primer o último registro, porque la moda representa mejor el valor “más probablemente correcto” cuando existen errores de captura dispersos:

```
find_mode <- function(x) {
  x <- x[!is.na(x)]
  if (length(x) == 0) return(NA)
  u <- unique(x)
  u[which.max(tabulate(match(x, u)))]
}
```

Las categorías equivalentes se unificaron explícitamente ("MASCULINO" → "M", "MAE" → "TITULAR", "FILHO" → "DEPENDENTE", "IGNORADO" → "Não Informado"), y las categorías de baja frecuencia en variables de alta cardinalidad (como TIPO_UNIDADE_PREST_HOSPITALAR) se agruparon en una categoría "Outro" para evitar coeficientes inestables en los modelos posteriores:

```
agrupar_categorias_raras <- function(x, min_freq = 30) {
  frecuencias <- table(x)
  categorias_raras <- names(frecuencias[frecuencias < min_freq])
  x <- as.character(x)
  x[x %in% categorias_raras] <- "Outro"
  factor(x)
}
```

Respecto a las 302 edades faltantes: se decidió **excluir**las del modelo de clasificación en lugar de imputarlas, porque representan solo el **0.047%** del total de beneficiarios y, adicionalmente, ninguno de esos 302 registros tiene ansiedad diagnosticada — por lo que su exclusión no sesga la variable objetivo ni reduce de forma relevante el tamaño de muestra disponible.

3 Construcción de variables a nivel de beneficiario

Dado que la unidad de análisis del modelo de clasificación es el **beneficiario** (CHAVE_FUNCIONAL), fue necesario agregar toda la información transaccional en una sola fila por beneficiario. Se construyeron las siguientes variables:

Variable	Descripción
EDADE	Edad calculada a partir de la fecha de nacimiento
SEXO_BENEFICIARIO, TIPO_BENEFICIARIO	Moda por beneficiario, con recodificación de categorías

Variable	Descripción
VALOR_PROCEDIMIENTO_TOTAL	Suma de VALOR_UTILIZACAO de todo el historial
MEDIA_VALOR_PROCEDIMIENTO	Promedio de VALOR_UTILIZACAO por procedimiento
MAX_VALOR_PROCEDIMIENTO	Valor máximo de un procedimiento individual
N_UTILIZACAO	Número de fechas distintas de utilización
N_PROCEDIMENTOS / N_PROCEDIMENTOS_DIFERENTES	Conteo total y de procedimientos distintos
N_DIAGNOSTICOS_DIFERENTES	Número de CID distintos registrados
Consulta, Exame, Terapia, Internacao, Pronto Socorro, Outros	Frecuencia de cada tipo de atención (CETIPO), obtenida mediante <code>pivot_wider</code>
TIPO_UNIDADE_PREST_HOSPITALAR, UF_CNES_PREST_HOSPITALAR	Moda por beneficiario

Es importante remarcar que **N_DIAGNOSTICOS_DIFERENTES** cuenta **CID distintos en general**, no el CID F41 usado para construir la etiqueta — de esta forma se evita fuga de información (*data leakage*) directa. El CID, la CHAVE_FUNCIONAL y las fechas crudas se excluyeron explícitamente de las variables predictoras.

4 Análisis descriptivo

- Beneficiarios totales: **653,631**; con ansiedad: **419** (0.064%).
- Utilizaciones totales: **9,345,278**; de beneficiarios con ansiedad: **6,608**.
- Procedimientos totales (combinación única CHAVE_FUNCIONAL + DT_UTILIZACAO
 - CD_PROCEDIMENTO, para evitar conteos duplicados): **6,627,032**; de beneficiarios con ansiedad: **5,134**.




Figure 1: Comparación de distribución etaria entre beneficiarios y beneficiarios con ansiedad

- La edad promedio de la población general es de 38 años, mientras que en el subgrupo con ansiedad la edad promedio es de 2 años, lo cual sugiere que la ansiedad diagnosticada en esta base no se distribuye uniformemente entre grupos etarios.




Figure 2: Comparación de la distribución sexual entre beneficiarios y beneficiarios con ansiedad

- El tipo de especialidad más frecuentado por la población general es el examen y luego la internación con Terapia una de las ultimas especialidades consultadas, en cambio para la población con ansiedad se consulta con mayor frecuencia los servicios de Terapia, lo cual es congruente con el tipo de enfermedad psicologica como es la ansiedad.

El hallazgo más determinante de todo el análisis descriptivo, sin embargo, es simplemente la **prevalencia**: con menos de 7 casos por cada 10,000 beneficiarios, cualquier modelo de clasificación enfrenta un desbalance extremo, lo cual se discute en detalle en la siguiente sección.

- La distribución por sexo en el subgrupo con ansiedad (F: 227, M: 185, No informado: 7) es proporcionalmente distinta a la de la población general (F: 360,143, M: 263,627, No informado: 30,386), lo que sugiere una posible mayor prevalencia relativa en mujeres, consistente con la literatura epidemiológica sobre trastornos de ansiedad.
- La distribución de las especialidades accedidas por la población general comparada a la distribución de los servicios accedidos por la población diagnosticada con ansiedad es coherente, pues al ser una enfermedad mental se entiende que va a existir una prevalencia mayor en los servicios de terapia ofrecidos por el prestador.

5 Modelamiento predictivo

5.1 Estrategia general

Se entrenaron y compararon **tres modelos de clasificación**: Regresión Logística, XGBoost y Random Forest. En los tres casos se usó una partición estratificada 75/25 (`createDataPartition`), se excluyeron




Figure 3: Comparación de la consulta por especialidad entre beneficiarios y beneficiarios con ansiedad

variables con riesgo de fuga de información, y se seleccionó el umbral de clasificación mediante el índice de Youden sobre el conjunto de entrenamiento, en lugar de usar el valor por defecto de 0.5, dado el desbalance de clases.

Dada la prevalencia de 0.064%, se decidió que **la métrica principal para comparar modelos sería el PR-AUC** (área bajo la curva Precisión-Recall) en lugar de Accuracy o incluso ROC-AUC. La razón es que, con un desbalance tan extremo, el Accuracy es trivialmente alto para cualquier modelo que prediga mayoritariamente “No” (bastaría con clasificar todo como negativo para obtener >99.9% de accuracy), y el ROC-AUC puede verse artificialmente alto incluso cuando el modelo genera muchos falsos positivos en términos absolutos. El PR-AUC, en cambio, es sensible precisamente a ese problema.

5.2 Regresión logística

Para la regresión logística se optó por **sobremuestreo** (upSample) del conjunto de entrenamiento, de forma que la clase minoritaria quedara representada en igual proporción que la mayoritaria antes de ajustar el modelo.

Durante la construcción del modelo se detectó un problema de **colinealidad exacta**: la variable de número de procedimientos totales resultó ser combinación lineal de las columnas de frecuencia por tipo de especialidad (Consulta, Exame, Terapia, etc.), por lo que se eliminó del conjunto de predictoras. Adicionalmente, el diagnóstico de `alias()` reveló que `TIPO_BENEFICIARIO = "Não Informado"` coincidía perfectamente, registro a registro, con `SEXO_BENEFICIARIO = "Não Informado"` — es decir, ambas columnas codificaban la misma ausencia de información. Se optó por **excluir esos registros** del modelo de clasificación, dado que representan datos genuinamente incompletos del beneficiario.

También se revisó el VIF (ajustado por grados de libertad para las variables categóricas, usando $\text{GVIF}^*(1/(2 \cdot \text{Df}))$) y se encontró que, si bien algunas variables categóricas mostraban GVIF crudo elevado (`TIPO_UNIDADE_PREST_HOSPITALAR`: 45.5, `UF_CNES_PREST_HOSPITALAR`: 21.2), sus valores ajustados eran en realidad aceptables — un recordatorio de que el GVIF crudo no es directamente comparable al umbral clásico de 5-10 cuando hay factores con múltiples niveles. Aun así, se decidió eliminar `TIPO_UNIDADE_PREST_HOSPITALAR` del modelo logístico por la gran cantidad de niveles con muy pocas observaciones, que generaban inestabilidad en los coeficientes.

```
set.seed(12345)

vars_excluir <- c("CHAVE_FUNCIONAL", "CID", "DT_UTILIZACAO",
                  "DT_NASCIMENTO_BENEFICIARIO", "N_PROCEDIMENTOS",
```

```

"TIPO_UNIDADE_PREST_HOSPITALAR")

df_modelo <- df_benef %>% select(-any_of(vars_excluir))
df_modelo <- df_modelo %>%
  mutate(across(where(is.numeric), ~ ifelse(is.na(.x), median(.x, na.rm = TRUE), .x)))

idx_train <- createDataPartition(df_modelo$ANSIEDADE, p = 0.75, list = FALSE)
train_data <- df_modelo[idx_train, ]
test_data <- df_modelo[-idx_train, ]

train_bal <- upSample(x = train_data %>% select(-ANSIEDADE),
  y = train_data$ANSIEDADE, yname = "ANSIEDADE")

modelo_logit <- glm(ANSIEDADE ~ ., data = train_bal, family = binomial)

pred_prob_train <- predict(modelo_logit, newdata = train_bal, type = "response")
roc_train <- roc(train_bal$ANSIEDADE, pred_prob_train, levels = c("No", "Si"), direction = "<")
umbral_optimo <- coords(roc_train, "best", best.method = "youden")$threshold

```

Métricas obtenidas en TEST:

Métrica	Valor
Accuracy	0.9046
Sensibilidad	0.6442
Especificidad	0.9048
F1-score	0.0085
ROC-AUC	0.8411
PR-AUC	0.0072

Este resultado es, en sí mismo, el hallazgo más informativo de esta sección: el ROC-AUC (0.84) sugiere una discriminación razonable, pero el F1 y el PR-AUC son casi nulos. Esto ocurre porque, dada la prevalencia de 0.064%, incluso una especificidad “buena” en términos relativos (90%) implica un número absoluto enorme de falsos positivos frente a los escasos verdaderos positivos, lo que hunde la precisión y, con ella, el F1 y el PR-AUC. El Accuracy alto es, en este contexto, prácticamente irrelevante como indicador de calidad del modelo.

5.3 XGBoost

Para XGBoost se abandonó el sobremuestreo y se optó por **scale_pos_weight**, que ajusta el gradiente de aprendizaje sin duplicar observaciones — una alternativa más apropiada para modelos de árboles. Se realizó una búsqueda de hiperparámetros por validación cruzada de 5 folds, optimizando directamente sobre PR-AUC, sobre una grilla de **max_depth**, **eta** y **min_child_weight**. La mejor configuración encontrada fue **max_depth = 7**, **eta = 0.1**, **min_child_weight = 1**, con 200 iteraciones óptimas.

```

train_matrix <- sparse.model.matrix(ANSIEDADE ~ . - 1, data = train_data)
test_matrix <- sparse.model.matrix(ANSIEDADE ~ . - 1, data = test_data)

label_train <- ifelse(train_data$ANSIEDADE == "Si", 1, 0)
label_test <- ifelse(test_data$ANSIEDADE == "Si", 1, 0)

scale_pos_weight <- sum(label_train == 0) / sum(label_train == 1)

```

```
dtrain <- xgb.DMatrix(data = train_matrix, label = label_train)
dtest  <- xgb.DMatrix(data = test_matrix,  label = label_test)

params_finales <- list(
  objective = "binary:logistic", eval_metric = "aucpr",
  max_depth = 7, eta = 0.1, min_child_weight = 1,
  subsample = 0.8, colsample_bytree = 0.8,
  scale_pos_weight = scale_pos_weight
)

modelo_xgb <- xgb.train(params = params_finales, data = dtrain, nrounds = 200,
                        evals = list(train = dtrain, test = dtest), verbose = 0)
```

Métricas obtenidas en TEST:

Métrica	Valor
Accuracy	0.9996
Sensibilidad	0.5000
Especificidad	0.9999
F1-score	0.6228
ROC-AUC	0.9814
PR-AUC	0.6942

5.4 Random Forest

Se usó el paquete **ranger** en lugar de **randomForest**, principalmente porque maneja de forma nativa variables categóricas de alta cardinalidad sin necesidad de construir matrices dummy, evitando así los errores de “niveles nuevos” (**new levels**) que sí se presentaron al trabajar con matrices dispersas en XGBoost. El desbalance se trató mediante **class.weights**, calculado como el inverso de la proporción de cada clase. Se realizó una búsqueda de hiperparámetros (**mtry**, **min.node.size**) por validación cruzada manual de 5 folds, optimizando PR-AUC.

```
prop_clases <- prop.table(table(train_data$ANSIEDADE))
pesos_clase <- c("No" = 1/prop_clases[["No"]], "Si" = 1/prop_clases[["Si"]])
pesos_clase <- pesos_clase / sum(pesos_clase)

modelo_rf <- ranger(
  formula = ANSIEDADE ~ ., data = train_data,
  num.trees = 500, mtry = 5, min.node.size = 1,
  class.weights = pesos_clase, probability = TRUE,
  importance = "permutation", seed = 2016325
)
```

Métricas obtenidas en TEST:

Métrica	Valor
Accuracy	0.9996
Sensibilidad	0.6346
Especificidad	0.9998
F1-score	0.6471

Métrica	Valor
ROC-AUC	0.9798
PR-AUC	0.7189

5.5 Comparación de modelos

Modelo	Accuracy	Sensibilidad	Especificidad	F1	ROC-AUC	PR-AUC
Regresión Logística (upsample)	0.9046	0.6442	0.9048	0.0085	0.8411	0.0072
XGBoost (scale_pos_weight)	0.9996	0.5000	0.9999	0.6228	0.9814	0.6942
Random Forest	0.9996	0.6346	0.9998	0.6471	0.9798	0.7189

Tomando PR-AUC como criterio principal (justificado por el desbalance extremo de la variable objetivo), **Random Forest** resultó el mejor modelo, seguido muy de cerca por XGBoost, y muy por delante de la regresión logística. Ambos modelos de ensamble superan holgadamente el umbral de 85% en ROC-AUC que sugiere el enunciado como referencia positiva, aunque —como se explica en la sección de interpretación— el ROC-AUC no es la métrica más relevante en este problema.

6 Interpretación de resultados

6.1 Por qué la regresión logística falló y los ensambles no

La diferencia de desempeño entre la regresión logística y los modelos de árboles no es un accidente de ajuste de hiperparámetros: la logística asume una relación lineal (en la escala del logit) entre cada predictora y la probabilidad de ansiedad. Es razonable pensar que el riesgo real depende de **interacciones** entre variables (por ejemplo, el efecto de la edad puede ser distinto según si el beneficiario ha sido internado, o el efecto del número de especialidades distintas consultadas puede depender del tipo de beneficiario). Random Forest y XGBoost capturan estas interacciones de forma automática, lo que explica la mejora sustancial en F1 y PR-AUC sin necesidad de que el analista especifique manualmente cada interacción relevante.

6.2 Variables más influyentes

En Random Forest, la importancia por permutación (más confiable que la importancia por impureza de Gini cuando las variables tienen distinta cardinalidad) señaló como más relevantes las variables relacionadas con la **frecuencia de utilización de servicios de salud mental** (especialidades consultadas, número de utilizations, número de diagnósticos distintos), lo cual es clínicamente coherente: un beneficiario que interactúa con más frecuencia y diversidad con el sistema de salud tiene más oportunidades de recibir (y de que quede registrado) un diagnóstico de ansiedad.

6.3 Análisis de errores y limitaciones del modelo

La sensibilidad de los tres modelos se mantiene en un rango de 0.50-0.64, es decir, incluso el mejor modelo deja sin detectar entre un tercio y la mitad de los verdaderos casos de ansiedad. Esto es consistente con una limitación estructural de los datos administrativos de utilización: **el registro de un CID depende**

de que el evento haya sido diagnosticado y codificado correctamente, por lo que es esperable que existan beneficiarios con ansiedad no diagnosticada (falsos negativos por definición del *gold standard*, no necesariamente errores del modelo). Esto debe entenderse como un límite de la fuente de datos, no solo del algoritmo.

7 Estimación del costo asociado a la enfermedad

7.1 Definición de la unidad de análisis

Se decidió estimar el costo usando `MEDIA_VALOR_PROCEDIMIENTO` (el promedio de `VALOR_UTILIZACAO` por procedimiento, a nivel de beneficiario) como variable respuesta, calculada únicamente sobre los 419 beneficiarios con ansiedad diagnosticada. Es importante ser transparentes sobre la limitación de esta elección: al trabajar con el **promedio** por procedimiento en lugar del **costo total** acumulado, la variable no refleja cuántos procedimientos tuvo cada beneficiario, sino el “precio típico” de sus atenciones — dos beneficiarios con el mismo promedio pueden tener cargas de atención (y costo total real para el sistema) muy distintas. Esta es una limitación reconocida del análisis, discutida más adelante.

```
df_benef_costo <- df_benef %>%  
  filter(MEDIA_VALOR_PROCEDIMIENTO > 0 & ANSIEDADE == 1)
```

7.2 Análisis descriptivo del costo

El costo promedio por procedimiento en la población con ansiedad muestra un **coeficiente de variación alto y asimetría positiva marcada**: la mayoría de los procedimientos se concentran en valores bajos (dominados por un pico muy pronunciado alrededor de 35, que se identificó como la **tarifa estandarizada de las sesiones de terapia**), mientras que una minoría de casos —asociados a internación y UCI— alcanza valores mucho más altos, generando una cola larga a la derecha en la distribución.

Al clasificar los registros como *outliers* mediante el criterio de rango intercuartílico, se encontró que representan un **12.65%** del total —una proporción demasiado alta para tratarse de errores de captura. El grupo “outlier” mostró una edad promedio de 33.4 años frente a 21.7 años en el resto, y un costo promedio casi 18 veces mayor (7,720 frente a 420). Esta evidencia respalda que los valores extremos son **casos clínicamente distintos** (posiblemente de mayor severidad o edad), no ruido, y por tanto no se eliminaron sino que se modelaron explícitamente.

7.3 Modelo de costo

Se ajustó un **GLM Gamma con enlace log**, apropiado para una variable respuesta estrictamente positiva y con varianza creciente en la media, como es típico en costos de salud. El proceso de especificación del modelo requirió resolver varios problemas encontrados en el camino:

1. **Colinealidad exacta** entre `TIPO_BENEFICIARIO = "Não Informado"` y `SEXO_BENEFICIARIO = "Não Informado"` (la misma detectada en el modelo de clasificación): se resolvió excluyendo esos registros.
2. **VIF alto (23.6) en `N_PROCEDIMENTOS_DIFERENTES`**, redundante con las variables de frecuencia por tipo de atención (`Exame`, `Terapia`, etc.): se eliminó del modelo, lo que redujo también el VIF de `Exame` (de 19.7 a 2.2) y de `N_UTILIZACAO` (de 7.3 a 5.8).
3. **Falta de convergencia del algoritmo** (`glm.fit: algorithm did not converge`), resuelta aumentando el número máximo de iteraciones (`glm.control(maxit = 100)`).

```

costo_modelo <- df_benef_costo %>%
  mutate(across(where(is.character), as.factor)) %>%
  mutate(across(where(is.factor), droplevels)) %>%
  dplyr::select(-CHAVE_FUNCIONAL, -ANSIEDADE, -N_PROCEDIMENTOS,
               -VALOR_PROCEDIMENTO_TOTAL, -MAX_VALOR_PROCEDIMENTO,
               -N_PROCEDIMENTOS_DIFERENTES) %>%
  filter(!is.na(EDADE), TIPO_BENEFICIARIO != "Não Informado")

idx_train_costo <- sample(seq_len(nrow(costo_modelo)), size = 0.75 * nrow(costo_modelo))
train_costo <- costo_modelo[idx_train_costo, ]
test_costo <- costo_modelo[-idx_train_costo, ]

modelo_costo <- glm(
  MEDIA_VALOR_PROCEDIMENTO ~ .,
  data = train_costo, family = Gamma(link = "log"),
  control = glm.control(maxit = 100, epsilon = 1e-8)
)

```

7.3.1 Evaluación y el trade-off sesgo-varianza

Una primera versión del modelo (que incluía un spline de edad con boundary knots ajustados solo al rango del conjunto de entrenamiento, y categorías de baja frecuencia sin agrupar) alcanzó un pseudo R^2 aparentemente alto (0.5711), pero al evaluarlo se descubrió que generaba **predicciones absurdas**: para un caso con costo real de 33,625, el modelo predijo **3,465,273** — un factor de sobreestimación de ~103 veces. La causa fue identificada como la combinación de una categoría de unidad hospitalaria con muy pocas observaciones en entrenamiento y una extrapolación inestable del spline de edad fuera del rango observado, potenciadas mutuamente por el efecto multiplicativo del enlace log.

Al **agrupar las categorías raras** de TIPO_UNIDADE_PREST_HOSPITALAR y UF_CNES_PREST_HOSPITALAR (categorías con menos de 30 observaciones recodificadas como "Outro"), el modelo se volvió estable (`modelo_costo$converged == TRUE`) y la predicción extrema desapareció, pero a costa de un pseudo R^2 más modesto (0.2229).

Métricas comparadas:

Métrica	Modelo inicial (inestable)	Modelo final (estable)
MAE	39,284.92	2,529.65
RMSE	340,502.60	15,190.70
MAPE	198.34%	129.40%
Pseudo R^2	0.5711	0.2229

Esta comparación es, en mi opinión, uno de los hallazgos más valiosos de todo el ejercicio: el modelo con mayor R^2 aparente en realidad estaba **memorizando** categorías raras del entrenamiento en lugar de generalizar, y por eso colapsaba al enfrentar datos nuevos. El modelo final, con un R^2 más bajo, es sustancialmente más confiable para predicción fuera de muestra (MAE y RMSE se redujeron entre 10 y 20 veces). Esto ilustra de forma muy concreta el trade-off sesgo-varianza: “mejor ajuste a los datos observados” no es sinónimo de “mejor modelo”.

Cabe señalar que tanto el MAPE final (129 como el pseudo $R^2 = 0.22$) siguen siendo modestos en términos absolutos. Esto es, en parte, esperable dado el tamaño de muestra reducido (419 beneficiarios) y la naturaleza inherentemente heterogénea del costo en salud, y se retoma como limitación en la sección final.

7.4 Intento de modelo en dos partes

Al observar en el histograma en escala logarítmica una **masa puntual muy pronunciada** alrededor de un valor específico (correspondiente a la tarifa estandarizada de terapia), se planteó la hipótesis de que el costo no sigue una única distribución continua, sino una mezcla de “regímenes de precio” (tarifas fijas de terapia/consulta frente a costos variables de exámenes, urgencias e internación). Para poner a prueba esta hipótesis se implementó un **modelo en dos partes**: (1) un modelo logístico que clasifica cada beneficiario como “caso simple” o “caso complejo” según el tipo de atención predominante, y (2) dos modelos Gamma independientes —uno para cada subgrupo— cuya predicción se combina ponderando por la probabilidad estimada en la primera etapa.

```
costo_modelo_2p <- costo_modelo %>%
  mutate(
    caso_complejo = case_when(
      Internacao > 0 | `Pronto Socorro` > 0 ~ "Si",
      Exame > pmax(Consulta, Outros, Terapia) ~ "Si",
      Terapia > pmax(Consulta, Outros) ~ "No",
      Consulta > pmax(Terapia, Outros) ~ "No",
      TRUE ~ "Si"
    ),
    caso_complejo = factor(caso_complejo, levels = c("No", "Si"))
  )
```

Resultado: el modelo en dos partes **empeoró** el desempeño en todas las métricas frente al modelo único (MAE +54, RMSE +221, pseudo $R^2 = 0.092$). La explicación más plausible es que, al dividir una muestra ya pequeña (419 beneficiarios) en dos subgrupos, cada submodelo quedó con muy pocas observaciones para estimar coeficientes de forma estable, y el error de clasificación de la primera etapa se propaga y amplifica en la combinación final. Se decidió **descartar este enfoque** y conservar el GLM Gamma único como modelo final de costo, dejando el modelo de dos partes documentado como un experimento razonable que no funcionó con el tamaño de muestra disponible — y como posible línea de trabajo futuro si se dispusiera de más datos.

7.5 Costo esperado bajo distintos perfiles

Usando el modelo final, se estimó el costo esperado para dos perfiles contrastantes: un beneficiario ambulatorio de 40 años sin UCI ni internación, y un beneficiario de 70 años internado y con paso por UCI. Como es de esperar dado el análisis de outliers, el segundo perfil presenta un costo esperado sustancialmente mayor, consistente con el hallazgo de que edad, internación y UCI son los factores más asociados al incremento del costo.

8 Conclusiones, limitaciones y trabajos futuros

¿Qué tan bien se logró identificar a los beneficiarios con ansiedad? Razonablemente bien en términos de discriminación general (ROC-AUC > 0.97 en los modelos de ensamble), pero de forma más modesta si se exige buena precisión (PR-AUC ≈ 0.72 con Random Forest). La sensibilidad limitada (0.63) sugiere que una parte no trivial de los casos reales de ansiedad no son capturados por el modelo, probablemente por una combinación de subdiagnóstico real en la base y de solapamiento de patrones de utilización con otras condiciones de salud mental o crónicas.

¿Qué variables están más relacionadas con la enfermedad? Principalmente la intensidad y diversidad de la utilización de servicios de salud (número de utilizaciones, diagnósticos distintos, especialidades consultadas), más que variables puramente demográficas.

¿Qué tan confiable es el modelo construido? El modelo de clasificación (Random Forest) es razonablemente confiable para tareas de discriminación, pero su utilidad práctica directa como herramienta de tamizaje individual es limitada por su sensibilidad moderada. El modelo de costo, en su versión final, es estable y generalizable, aunque explica solo una fracción moderada de la variabilidad total del costo ($pseudoR^2 = 0.22$).

¿Qué limitaciones tiene la base de datos? Prevalencia extremadamente baja de la enfermedad seleccionada (0.064%), inconsistencias de captura (sexo y tipo de beneficiario contradictorios, fechas de nacimiento inválidas), categorías con muy pocas observaciones en variables de alta cardinalidad (unidad hospitalaria, estado), y ausencia de información sobre severidad clínica más allá de proxies administrativos (UTI, internación).

¿Qué limitaciones tiene la estrategia de modelamiento? El uso del **promedio** de valor por procedimiento en lugar del costo total acumulado subestima la carga real de atención de beneficiarios con muchas utilidades. El modelo de costo, al agrupar categorías raras para ganar estabilidad, pierde parte de la señal específica de esas categorías. El modelo en dos partes no resultó viable con el tamaño de muestra disponible.

¿Qué mejoras podrían realizarse en un trabajo futuro? (1) Repetir la estimación de costo usando el costo total acumulado por beneficiario o por utilización, en lugar del promedio por procedimiento, para capturar mejor la carga real sobre el sistema. (2) Revisar el modelo en dos partes con una muestra de mayor tamaño, donde cada submodelo tenga suficientes observaciones para estimarse con estabilidad. (3) Incorporar interacciones explícitas (edad $\times$ internación, por ejemplo) en el modelo de costo, dado que se sospechó mediación entre edad y severidad clínica. (4) Consultar con un experto clínico o de salud pública la definición más adecuada de “caso complejo” para un eventual modelo de dos partes, en lugar de una regla heurística basada solo en frecuencias de tipo de atención.