

Taller 3

Asignatura: Minería de Datos

Código: 2016325

Porcentaje: 25 %

Fecha limite de entrega: 7 de julio de 2026.

Modalidad: individual.

Horario de atención: Viernes 10:00-12:00.

Temas: Clases 12-19.

1. Objetivo

El objetivo del taller es desarrollar un análisis completo de minería de datos aplicado a una base real de utilización de servicios de salud. Cada estudiante deberá seleccionar una enfermedad o condición clínica identificable mediante códigos CID (que esten presentes en la base de datos), construir una variable objetivo binaria a nivel de beneficiario, entrenar y evaluar modelos predictivos, interpretar los resultados obtenidos y estimar el costo esperado asociado a la enfermedad seleccionada. El trabajo debe integrar las principales fases del proceso de minería de datos: comprensión del problema, preparación de los datos, análisis descriptivo, construcción de variables, modelamiento, evaluación, interpretación de resultados y comunicación de hallazgos.

2. Actividad

2.1. Contexto de la base de datos

En este taller se trabajará con una base de datos real de utilización de servicios de salud. Cada registro corresponde a una utilización médica o procedimiento asociado a un beneficiario. La variable `CHAVE_FUNCIONAL` identifica al beneficiario y la variable `DT_UTILIZACION` corresponde a la fecha de utilización del plan. Dado que se trata de una base de datos real, pueden existir problemas de calidad de datos, tales como valores faltantes, inconsistencias entre registros de un mismo beneficiario, categorías mal codificadas, fechas inválidas, valores extremos o información contradictoria. Por ejemplo, una misma `CHAVE_FUNCIONAL` podría aparecer asociada a más de un sexo en diferentes transacciones. El estudiante deberá identi-

ficar estos problemas, proponer una estrategia de tratamiento y justificar por qué considera que su decisión es adecuada para el problema de modelamiento.

2.2. Descripción de las variables

La base de datos contiene los siguientes campos:

- CID: código diagnóstico asociado a la utilización.
- UTI: indicador de si la persona pasó por UCI.
- INTERNADO: indicador de si la persona estuvo internada.
- PORTE_ANESTESICO: nivel de anestesia aplicado.
- DT_UTILIZACAO: fecha de utilización del plan.
- DESC_ESPECIALIDADE: especialidad del médico o servicio que atendió la consulta.
- TIPO_UNIDADE_PREST_HOSPITALAR: tipo de unidad hospitalaria donde fue atendida la persona.
- UF_CNES_PREST_HOSPITALAR: estado/región donde se encuentra el hospital.
- DT_NASCIMENTO_BENEFICIARIO: fecha de nacimiento del beneficiario.
- TIPO_BENEFICIARIO: tipo de beneficiario.
- SEXO_BENEFICIARIO: sexo del beneficiario.
- CETIPO: clasificación del tipo de utilización o procedimiento aplicado. Los valores posibles son:
 - C: consulta.
 - E: examen.
 - T: terapia.
 - I: internación.
 - P: pronto socorro o urgencias.
 - O: otros.
- CD_PROCEDIMENTO: código del procedimiento realizado.
- DESCRICAO_PROCEDIMENTO: descripción del procedimiento realizado.
- VALOR_UTILIZACAO: costo de la utilización o procedimiento.

- **CHAVE_FUNCIONAL**: identificador del beneficiario.

Es importante diferenciar entre **CID** y **CD_PROCEDIMIENTO**. La variable **CID** corresponde al código diagnóstico o enfermedad asociada a la utilización, mientras que **CD_PROCEDIMIENTO** corresponde al código del procedimiento realizado.

2.3. Granularidad de la base

La base puede analizarse en diferentes niveles de granularidad:

- **Beneficiario**: identificado por **CHAVE_FUNCIONAL**.
- **Consulta o utilización**: aproximada por la combinación de **CHAVE_FUNCIONAL** y **DT_UTILIZACAO**.
- **Procedimiento**: identificado por la información de la utilización junto con **CD_PROCEDIMIENTO**.

Para efectos del análisis, una consulta o utilización puede aproximarse mediante la combinación de **CHAVE_FUNCIONAL** y **DT_UTILIZACAO**, es decir, una atención realizada a un beneficiario en una fecha específica. Sin embargo, una misma consulta puede estar asociada a más de un procedimiento, por lo que el estudiante deberá tener cuidado al agregar la información y evitar conteos duplicados.

2.4. Construcción de la variable objetivo

Cada estudiante deberá seleccionar una enfermedad o condición clínica identificable mediante códigos **CID**. A partir de esa definición, deberá construir una variable objetivo binaria a nivel de beneficiario. La variable **CHAVE_FUNCIONAL** identifica a cada beneficiario. Por tanto, si un beneficiario presenta al menos una transacción con un **CID** asociado a la enfermedad seleccionada, dicho beneficiario deberá recibir la etiqueta 1; en caso contrario, deberá recibir la etiqueta 0. Por ejemplo, para diabetes se pueden considerar los códigos **CID** entre E10 y E14. En este caso, todos los beneficiarios que tengan al menos una transacción asociada a alguno de estos códigos deberán recibir la etiqueta 1 para el modelo de diabetes, mientras que los demás beneficiarios deberán recibir la etiqueta 0.

2.5. Fuentes de consulta recomendadas

Para comprender mejor los códigos utilizados en la base de datos, se recomienda consultar fuentes oficiales de referencia. La variable **CID** puede consultarse en la Clasificación Internacional de Enfermedades, CIE-10/ICD-10, publicada por la Organización Mundial de la Salud.

La variable `CD_PROCEDIMENTO` está relacionada con códigos de procedimientos utilizados en el contexto de salud suplementaria en Brasil, particularmente con la TUSS (Terminologia Unificada da Saúde Suplementar), administrada por la ANS.

- OMS – ICD-10 Browser: <https://icd.who.int/browse10/2019/en>
- OMS – International Classification of Diseases: <https://www.who.int/standards/classifications/classification-of-diseases>
- ANS – Padrão TISS / Tabelas relacionadas: <https://www.gov.br/ans/pt-br/assuntos/prestadores/padrao-para-troca-de-informacao-de-saude-suplementar-2013-tiss/padrao-tiss-tabelas-relacionadas>

El estudiante deberá usar estas fuentes para justificar la enfermedad seleccionada, interpretar los códigos utilizados y documentar adecuadamente la construcción de la variable objetivo y de las variables predictoras.

2.6. Análisis descriptivo y preparación de los datos

El estudiante deberá realizar un análisis descriptivo de la base de datos y de la enfermedad seleccionada. Este análisis debe incluir, como mínimo:

- Número de beneficiarios analizados.
- Número de utilizaciones o consultas.
- Número de procedimientos.
- Distribución de la variable objetivo.
- Porcentaje de beneficiarios con la enfermedad seleccionada.
- Distribución por sexo, edad, tipo de beneficiario, estado y especialidad.
- Análisis de valores faltantes.
- Identificación de inconsistencias en los datos.
- Análisis de valores extremos en `VALOR_UTILIZACAO`.

El estudiante deberá construir variables a nivel de beneficiario a partir de la información disponible en la base. Algunas variables pueden estar relacionadas con edad, sexo, tipo de beneficiario, número de utilizaciones, número de procedimientos, especialidades consultadas, internaciones, uso de UCI, costos acumulados, costos promedio, estado de atención y tipo de unidad hospitalaria. Todas las decisiones tomadas durante la limpieza, transformación, agregación y selección de variables deberán ser documentadas y justificadas.

2.7. Modelamiento predictivo

El estudiante deberá entrenar y comparar más de un modelo de clasificación para estimar la probabilidad o riesgo de que un beneficiario pertenezca al grupo con la enfermedad seleccionada. La comparación de modelos deberá realizarse mediante una o más métricas adecuadas para el problema, tales como:

- Accuracy.
- F1-score.
- Sensibilidad.
- Especificidad.
- ROC-AUC.
- PR-AUC.

El estudiante deberá justificar la métrica principal seleccionada y discutir si el desempeño obtenido es adecuado para el contexto del problema. Como referencia, se valorará positivamente alcanzar un desempeño superior al 85 % en una métrica relevante, siempre que dicha métrica sea apropiada para la distribución de la variable objetivo.

2.8. Interpretación de resultados

Además del desempeño predictivo, el estudiante deberá interpretar los resultados del modelo. El análisis deberá incluir:

- Identificación de las variables más importantes o más influyentes en la predicción.
- Discusión de la posible relación entre dichas variables y la enfermedad seleccionada.
- Comparación entre los modelos entrenados.
- Análisis de errores del modelo.
- Discusión sobre posibles sesgos o limitaciones de los datos.

El estudiante podrá utilizar herramientas como importancia de variables, coeficientes del modelo, SHAP values, PDP, gráficos de dependencia parcial u otras estrategias de interpretación, según el tipo de modelo utilizado.

2.9. Estimación del costo asociado a la enfermedad

Como componente adicional, el estudiante deberá estimar el costo esperado de una utilización asociada a la enfermedad seleccionada. Para ello, deberá definir claramente cuál será la unidad de análisis utilizada para el costo, por ejemplo, procedimiento, consulta o beneficiario, y justificar su decisión. La estimación deberá construirse a partir de la variable `VALOR_UTILIZACAO` y considerar las características disponibles en la base de datos, como tipo de procedimiento, especialidad, internación, UCI, tipo de unidad hospitalaria, edad, sexo, estado y otras variables relevantes. El estudiante deberá presentar el costo promedio observado para la enfermedad seleccionada, analizar su variabilidad y construir una estrategia que permita estimar el costo esperado bajo diferentes perfiles o condiciones. Finalmente, deberá discutir qué variables parecen estar más asociadas al aumento o disminución del costo y cuáles son las limitaciones de la estimación realizada.

2.10. Conclusiones, limitaciones y trabajos futuros

El informe final deberá incluir una sección de conclusiones en la que el estudiante sintetice los principales hallazgos del análisis. También deberá discutir las limitaciones del trabajo realizado y proponer posibles trabajos futuros. Esta sección debe responder, como mínimo, a las siguientes preguntas:

- ¿Qué tan bien se logró identificar a los beneficiarios asociados a la enfermedad seleccionada?
- ¿Qué variables parecen estar más relacionadas con la enfermedad?
- ¿Qué tan confiable es el modelo construido?
- ¿Qué limitaciones tiene la base de datos?
- ¿Qué limitaciones tiene la estrategia de modelamiento utilizada?
- ¿Qué mejoras podrían realizarse en un trabajo futuro?

3. Despliegue: entrega mediante Pull Request

Cada estudiante deberá desarrollar y entregar todo su análisis dentro de su carpeta personal asignada en el repositorio de la clase. Todo el código utilizado para la preparación de datos, construcción de variables, entrenamiento de modelos, evaluación, interpretación de resultados y estimación de costos deberá estar incluido dentro de dicha carpeta personal. Asimismo, las tablas, gráficas, métricas y demás resultados generados deberán quedar documentados

o almacenados en esa misma carpeta. La entrega se realizará mediante un *pull request* al repositorio de GitHub de la clase. No se aceptarán entregas por fuera del repositorio ni archivos ubicados fuera de la carpeta personal del estudiante. El documento principal donde se explican y presentan los resultados deberá estar en formato Markdown, por ejemplo, `taller_3.Rmd`. Este documento deberá resumir el problema abordado, la enfermedad seleccionada, las decisiones metodológicas, los principales resultados, la interpretación del modelo, la estimación de costos, las conclusiones, las limitaciones y los posibles trabajos futuros.

3.1. Contenido mínimo dentro de la carpeta personal

La carpeta personal del estudiante debe incluir, como mínimo:

- Código reproducible para la preparación de datos.
- Código de construcción de la variable objetivo.
- Código de análisis descriptivo.
- Código de entrenamiento de los modelos.
- Código de evaluación y comparación de modelos.
- Código o salidas asociadas a la interpretación de variables importantes.
- Código o resultados asociados a la estimación del costo esperado.
- Documento en Markdown con la presentación y discusión de resultados.
- Instrucciones básicas para reproducir el análisis.

3.2. Lenguaje de programación

El estudiante podrá desarrollar el taller utilizando **R** o **Python**. La elección del lenguaje es libre, siempre que el análisis sea reproducible, el código esté bien documentado y todos los resultados puedan ser verificados a partir de los archivos entregados en el repositorio de GitHub de la clase.

3.3. Registro de la enfermedad seleccionada

Una vez el estudiante haya seleccionado la enfermedad o condición clínica que va a modelar, deberá registrar dicha elección en la planilla compartida. En esta planilla deberá indicar el nombre, grupo del curso, el nombre de la enfermedad seleccionada y el conjunto de códigos

CID que utilizará para construir la variable objetivo. Por ejemplo, si el estudiante selecciona diabetes, deberá registrar que la enfermedad corresponde a diabetes y que los códigos CID utilizados serán E10–E14.

Dos estudiantes **no podrán** trabajar con la misma enfermedad o condición clínica. Por tanto, antes de iniciar el análisis, cada estudiante deberá verificar en la planilla que la enfermedad seleccionada no haya sido registrada previamente por otro compañero. En caso de que una enfermedad ya esté asignada, el estudiante deberá escoger una enfermedad diferente.

La planilla de registro estará disponible en el siguiente enlace:

https://docs.google.com/spreadsheets/d/1ehxQNAudKlr_tfbdSjzIfUZU-5Mq3C26xvqQPz1QFBA/edit?gid=0#gid=0

3.4. Criterios de evaluación

Criterio	Descripción
Definición del problema	Claridad en la selección de la enfermedad, justificación de los códigos CID y construcción de la variable objetivo.
Calidad de datos	Identificación y tratamiento adecuado de datos faltantes, inconsistencias, valores extremos y problemas reales de la base.
Análisis descriptivo	Caracterización clara de la base de datos, de los beneficiarios y de la enfermedad seleccionada.
Construcción de variables	Agregación adecuada a nivel de beneficiario y creación de variables relevantes para el problema.
Modelamiento predictivo	Entrenamiento y comparación de más de un modelo de clasificación.
Evaluación del modelo	Uso de métricas adecuadas, interpretación del desempeño y discusión de los resultados.
Interpretabilidad	Identificación y análisis de las variables más importantes del modelo.
Estimación de costos	Estimación del costo esperado asociado a la enfermedad seleccionada y análisis de los factores relacionados con el costo.
Conclusiones y limitaciones	Discusión crítica de los hallazgos, limitaciones del análisis y posibles trabajos futuros.
Reproducibilidad y PR	Claridad del código, organización de la carpeta personal, documento Markdown y entrega mediante pull request.